ICT — 4202

ARTIFICIAL INTELLIGENCE & MACHINE LEARNING

সম্পূর্ণ বাংলা ল্যাব ভাইভা হ্যান্ডবুক

Set-wise Theory • Algorithms • Output Explanation • Viva Q&A

সহজ বাংলা ব্যাখ্যা | হাতে-কলমে Calculation | পরীক্ষকের “কেন/কীভাবে” প্রশ্ন

SET COVERAGE	EXPERIMENTS	VIVA QUESTION BANK
০১ – ১০	৩০টি (A, B, C)	৩৫৫টি Core + ৩০টি Set-Extra + Experiment Viva

উপযোগী: ICT-4202 Laboratory Final, Practical Examination ও Oral Viva

Department of Information and Communication Technology
Islamic University, Kushtia, Bangladesh

Study edition • October 2026

বইটি কীভাবে পড়বে

প্রথমে নিজের Set-এর তিনটি experiment পড়ো; তারপর Reference Q. নম্বর ধরে শেষের পূর্ণ Viva Bank থেকে আরও প্রশ্ন পড়ে নাও।

এক নজরে ১০ সেট × ৩ practical = ৩০টি experiment। প্রতিটি practical-এ Theory, Algorithm, Output, কেন এমন ফল এসেছে, Advantages, Disadvantages, Real Use এবং সম্ভাব্য viva রাখা হয়েছে।

সূচিপত্র (Set-wise)

অধ্যায়	যা পড়বে
SET 01	Agent + BFS/DFS/Greedy + Iris k-NN
SET 02	Forward Chaining + DLS/IDDFS + Regression
SET 03	FOL + A*/UCS + K-Means
SET 04	Bidirectional Search + WEKA + Regression
SET 05	Three-Room Agent + Greedy/A* + Decision Tree
SET 06	Eligibility Inference + Search + k-NN/Tree
SET 07	FOL Siblings + Greedy Heuristic + Scaled K-Means
SET 08	DLS/IDDFS + WEKA + Train/Test Regression
SET 09	Adjacency Order + A* Admissibility + K-Means
SET 10	Knowledge-Based Agent + BFS/Greedy/A* + Metrics
APPENDIX A	Complete 355 viva questions & short answers (1–355)
APPENDIX B	Search algorithm steps, formula sheet, numerical examples
APPENDIX C	High-yield comparisons, program output revision, extra viva tips

ব্যবহার ও সতর্কতা

১) সংখ্যাগুলো তোমার আলোচিত solution/settings অনুসারে লেখা। scikit-learn-এর version বা random initialization ভিন্ন হলে K-Means-এর metrics ও কয়েকটি classification result সামান্য বদলাতে পারে।

২) WEKA-এর Set 04-B ও 08-B-তে Python helper dataset যাচাই করে; J48/IBk-এর actual performance WEKA GUI থেকে record করতে হবে।

৩) Test data দিয়ে best hyperparameter বেছে নেওয়া শিক্ষামূলক demonstration হতে পারে; unbiased final assessment-এর জন্য training cross-validation + untouched test set উত্তম।

SET 01 / PRACTICAL REVISION

Set 01 — Agent + BFS/DFS/Greedy + Iris k-NN

এই Set-এর A, B, C—তিনটি experiment নিচে ধারাবাহিকভাবে দেওয়া হলো। প্রতিটি অধ্যায়ের শেষে sir-style reasoning question আছে।

Q1 | Simple Reflex Vacuum Cleaner + PEAS

THEORY Agent sensor দিয়ে environment-এর অবস্থা বোঝে, actuator দিয়ে কাজ করে। Simple Reflex Agent বর্তমান percept-এর উপর predefined rule প্রয়োগ করে। PEAS = Performance Measure, Environment, Actuator, Sensor। Vacuum-এর performance: সব ঘর পরিষ্কার, সময়/শক্তি কম খরচ।

Algorithm / Working Steps

1. Environment-এ A ও B-এর Clean/Dirty status এবং agent-এর location নির্ধারণ।
2. Current room Dirty হলে Suck করো।
3. Clean হলে অন্য প্রয়োজনীয় room-এ Move করো।
4. সব room clean হলে NoOp দিয়ে থামো।

EXPECTED OUTPUT প্রদর্শিত run-এ B Clean থাকা অবস্থায় agent Left হয়ে A-তে যায়; A Dirty হলে Suck করে; শেষে A ও B Clean হলে NoOp। Final state: A=Clean, B=Clean।

OUTPUT EXPLANATION NoOp মানে task সম্পন্ন; আর action দরকার নেই। Strict current-percept simple reflex agent শুধু বর্তমান percept জানে; lab implementation-এ global room status পাওয়া গেলে সেটি বেশি informative scenario।

GRAPH / TRACE Output action trace: Location → Percept → Action → Updated status।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
কম code, সহজ rules, তাৎক্ষণিক action।	Fixed rule-এ পরিবর্তনশীল পরিবেশ বা unseen situation handle করা কঠিন।	Robot vacuum, automated cleaning।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. PEAS-এর P কীভাবে define করবে?	সব room clean রাখা, action/time/energy cost কমানো।
Q2. সব room শুরু থেকেই Clean হলে?	NoOp; cleaning বা movement দরকার নেই।
Q3. Agent কি Decision Tree দিয়ে বানানো যায়?	হ্যাঁ, Dirty?→Suck-এর মতো rules Tree-তে করা যায়; কিন্তু এখানে if-else সহজ।

Full Question Bank link: Q. 1–20; 321–325

Q2 | BFS, DFS ও Greedy Best-First Search

THEORY Graph search-এ BFS FIFO Queue দিয়ে level-wise যায়, DFS LIFO Stack দিয়ে একটি branch ধরে গভীরে যায়, Greedy Priority Queue-তে minimum h(n) দেখে। BFS unit-cost setting-এ shortest-edge solution দেয়; Greedy shortest-cost guarantee দেয় না।

Algorithm / Working Steps

1. Start A, Goal G এবং adjacency graph নির্ধারণ।
2. BFS-এ Queue থেকে pop-left; DFS-এ Stack থেকে pop; Greedy-তে minimum h select।
3. Goal না হওয়া পর্যন্ত successor/visited manage এবং expanded order record।
4. Path, visited/expanded nodes ও count তুলনা।

EXPECTED OUTPUT BFS: A→B→D→G; expanded A,B,C,D,E,F,G (7)। DFS: A→B→D→G; expanded A,B,D,G (4)। Greedy: A→C→F→G; expanded A,C,F,G (4)।

OUTPUT EXPLANATION BFS level ধরে যায়; DFS প্রথম useful branch-এ G পায়। Greedy-তে h(C)=3 < h(B)=4, তাই C → F → G। DFS কম expansion করেছে মানেই সর্বক্ষেত্রে ভালো নয়; path-cost/guarantee আলাদা।

GRAPH / TRACE Trace-এ expanded sequence আর final path আলাদা জিনিস; দুটি আলাদাভাবে পড়বে।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
পদ্ধতিগুলোর search behavior পরিষ্কার তুলনা; BFS minimum-edge shortest path।	BFS বেশি memory; DFS/Greedy optimal নয়।	Unweighted maze, graph exploration, heuristic routing।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. BFS আর DFS-এর path একই হলে কোনটা ভালো?	Equal-cost shortest-path guarantee চাইলে BFS; এই run-এ expansion কম চাইলে DFS সুবিধা পেয়েছে।
Q2. Greedy h(n) কেন ব্যবহার করে?	Goal-এর বাকি distance/cost-এর estimate দিয়ে node prioritize করতে।
Q3. Expanded count ও path length কি একই?	না; expanded search effort, path length selected route-এর edges।

Full Question Bank link: Q. 53–85; 103–138; 143–145; 336–342

Q3 | Iris k-NN এবং Standardization

THEORY Iris-এ 150 samples, 4 features এবং 3 classes। k-NN supervised distance-based classifier; nearest k training points-এর majority vote দেয়। StandardScaler training mean/std দিয়ে feature standardize করে।

Algorithm / Working Steps

1. load_iris() → X features ও y target।
2. stratified 70/30 split: train=105, test=45।
3. k=1,3,5,7 দিয়ে k-NN fit, predict, accuracy compare।
4. Best k=5-এর Confusion Matrix ও classification report তৈরি।
5. Train-only fit করা scaler দিয়ে আবার scaled k-NN evaluate।

EXPECTED OUTPUT Test accuracy: k=1 93.33%, k=3 95.56%, k=5 97.78%, k=7 95.56%। Best k=5। Confusion Matrix [[15,0,0],[0,15,0],[0,1,14]]। Scaled k-NN accuracy ≈91.11%।

OUTPUT EXPLANATION Diagonal 15+15+14=44 correct /45 =97.78%; এক Virginica-কে Versicolor বলা হয়েছে। Scaling সবসময় accuracy বাড়ায় না। Test accuracy দিয়ে k বাছাই lab illustration; বাস্তবে training CV দিয়ে k select করা উত্তম।

GRAPH / TRACE Confusion Matrix: rows=actual, columns=predicted; diagonal=correct।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
Implementation সহজ; multiclass support।	Large training set-এ prediction slow; scaling ও k-sensitive।	Species/pattern classification, nearest-neighbor recommendation।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. Confusion Matrix-এর 1 কোথায়?	Actual Virginica row, Predicted Versicolor column—একটি misclassification।
Q2. Scaling কেন কম result দিয়েছে?	Distance ordering বদলেছে; এই split-এ তা helpful হয়নি।
Q3. k=5 কীভাবে predict?	Nearest পাঁচ training sample-এর majority class।

Full Question Bank link: Q. 146–181; 276–300; 321–335; 343; 345; 355

SET-LEVEL TRICKY VIVA BFS বনাম DFS—কোনটা ভালো? উত্তর: Equal edge-cost shortest path চাইলে BFS; এই particular run-এ DFS 4 nodes expand করেছে বনাম BFS 7, তাই কম effort-এ লক্ষ্য পেয়েছে; সর্বত্র DFS superior নয়।

SET 02 / PRACTICAL REVISION

Set 02 — Forward Chaining + DLS/IDDFS + Regression

এই Set-এর A, B, C—তিনটি experiment নিচে ধারাবাহিকভাবে দেওয়া হলো। প্রতিটি অধ্যায়ের শেষে sir-style reasoning question আছে।

Q1 | Forward Chaining: Weather Facts

THEORY Forward Chaining facts থেকে rules ব্যবহার করে নতুন facts যোগ করে, যতক্ষণ নতুন inference হয়। AND condition থাকলে সব antecedent সত্য লাগবে। Sample rules: Cloudy→Rain, Rain→WetGround, WetGround→Slippery, Slippery→DriveSlowly, Rain∧Cold→WearJacket।

Algorithm / Working Steps

1. Initial facts-এর Set তৈরি।
2. প্রতিটি rule-এর premises facts-এ আছে কি না পরীক্ষা।
3. শর্ত পূরণ হলে conclusion নতুন fact হিসেবে যোগ।
4. নতুন fact যোগ না হওয়া পর্যন্ত repeat।

EXPECTED OUTPUT Case A-তে Cloudy থেকে Rain, WetGround, Slippery, DriveSlowly; Cold না থাকায় WearJacket নয়। Case B-তে Cold যোগ থাকলে WearJacket-ও derive হয়।

OUTPUT EXPLANATION Rain ও Cold দুইটি premises একই সঙ্গে সত্য হলেই WearJacket inference। Derived facts list আসল deduction order দেখাতে পারে।

GRAPH / TRACE Fact chain: Cloudy → Rain → WetGround → Slippery → DriveSlowly।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
Rule-based সিদ্ধান্ত explainable।	Incomplete/contradictory facts বা অনেক rules জটিলতা বাড়ায়।	Weather advisory, expert systems।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. Cold না থাকলে WearJacket False?	Closed-world program-এ derive হবে না; pure logic-এ not provable সবসময় False নয়।
Q2. Rule chain কখন থামে?	নতুন conclusion আর যোগ না হলে।
Q3. এটা Decision Tree দিয়ে করা যায়?	কিছু final decisions যায়, কিন্তু multi-step rule inference আলাদা।

Full Question Bank link: Q. 21–35; 36–52

Q2 | Depth-Limited Search ও IDDFS

THEORY DLS হলো DFS যার সর্বোচ্চ depth limit আছে। IDDFS limit=0,1,2,... বাড়িয়ে বারবার DLS চালায়। তাই unknown-depth goal-এ BFS-এর shallowest-solution behavior এবং DFS-এর কম-memory স্বভাব মেলে।

Algorithm / Working Steps

1. DLS-এ (node, depth) track; goal আগে check।
2. Depth=limit হলে child expand নয়; possible cutoff।
3. IDDFS প্রথমে depth limit 0, পরের iteration-এ +1।
4. Success হলেই selected path return।

EXPECTED OUTPUT Start S, Goal G। DLS limit=2 → cutoff, no path। DLS limit=3 → S→A→D→G, success। IDDFS একই path, limit 0–3, root visits=4।

OUTPUT EXPLANATION Goal depth 3-এ, তাই depth 2 যথেষ্ট নয়। IDDFS প্রতি iteration root S থেকে নতুন করে শুরু করে, ফলে S চারবার visit হয়।

GRAPH / TRACE Iteration trace: limit 0 → 1 → 2 (cutoff) → 3 (success)।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
Limit-controlled search; IDDFS অজানা goal depth সামলায়।	Upper-level repeated work; low limit-এ solution miss।	Puzzle/maze, bounded game search।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. Cutoff মানেই কি goal নেই?	না, আরও গভীরে থাকতে পারে।
Q2. IDDFS কেন চারবার root visit?	Limits 0,1,2,3—চারটি iteration।
Q3. DLS DFS থেকে আলাদা কোথায়?	Max depth explicit cap।

Full Question Bank link: Q. 86–97; 336–342

Q3 | Simple Linear Regression ও Changed Target

THEORY Simple Linear Regression X ও numerical Y-এর fitted line শেখে: $\hat{y}=mx+c$। OLS squared prediction errors minimize করে slope ও intercept নির্ধারণ করে। $R^2=1-SSE/SST$।

Algorithm / Working Steps

1. X=[1,2,3,4,5,6], y=[4,5,8,9,11,14]।
2. LinearRegression().fit(X,y) দিয়ে parameters fit।
3. X=7-এ prediction এবং training R^2 বের।
4. Last y=14→18 করে refit ও তুলনা।

EXPECTED OUTPUT Original: slope≈1.9714, intercept=1.6000, pred(7)=15.4000, R^2≈0.9786। Modified: slope≈2.5429, intercept≈0.2667, pred(7)≈18.0667, R^2≈0.8922।

OUTPUT EXPLANATION শেষ score বাড়ায় fitted slope বেশি steep, intercept বদলে যায়। R^2 কমা মানে modified observations straight-line model-এর সঙ্গে তুলনামূলক কম মানানসই।

GRAPH / TRACE Scatter points-এর ওপর original ও modified fitted lines; modified শেষ observation-এর দিকে বেশি steep।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
সহজ, explainable, numerical prediction।	Outlier, nonlinearity ও extrapolation-sensitive।	Study hours vs score, sales trend।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. Slope কী?	X এক unit বাড়লে predicted Y-এর change।
Q2. Last y বাড়ালে slope কেন বাড়তে পারে?	Least-squares সব residual কমানোর জন্য fitted line বদলায়।
Q3. R^2 কি Accuracy?	না, R^2 regression metric; Accuracy classification metric।

Full Question Bank link: Q. 206–234; 321–335

SET-LEVEL TRICKY VIVA DLS cutoff আর failure কি একই? উত্তর: না। Cutoff-এর পর আরও গভীরে Goal থাকতে পারে; failure-এ relevant subtree explore করেও কোনো solution নেই।

SET 03 / PRACTICAL REVISION

Set 03 — FOL + A*/UCS + K-Means

এই Set-এর A, B, C—তিনটি experiment নিচে ধারাবাহিকভাবে দেওয়া হলো। প্রতিটি অধ্যায়ের শেষে sir-style reasoning question আছে।

Q1 | FOL Family Relations: Parent, Grandparent, Sibling

THEORY FOL-এ Parent(x,y) predicate দিয়ে সম্পর্ক প্রকাশ করা হয়। Rules: $Parent(x,y) \wedge Parent(y,z) \rightarrow Grandparent(x,z)$; $Parent(p,x) \wedge Parent(p,y) \wedge (x \neq y) \rightarrow Sibling(x,y)$।

Algorithm / Working Steps

1. Parent facts সংরক্ষণ।
2. Parent chain-এর দুই link মিলিয়ে Grandparent derive।
3. একই parent-এর distinct children খুঁজে Sibling derive।
4. Queries print ও known facts-এর সঙ্গে consistency check।

EXPECTED OUTPUT উদাহরণ: Parent(Ali,Babu), Parent(Babu,Karim) → Grandparent(Ali,Karim)। Parent(Ali,Babu), Parent(Ali,Rina) → Sibling(Babu,Rina)।

OUTPUT EXPLANATION একই parent দুইবার match করলেও self-sibling বাদ দিতে $x \neq y$ জরুরি। FOL symbolic inference করে, training labels দিয়ে classifier fit নয়।

GRAPH / TRACE Relation chain: Ali → Babu → Karim; Ali is Karim-এর grandparent।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
Explainable relational inference।	Incomplete facts-এ relation infer হবে না; বড় KB-তে complexity।	Genealogy, knowledge graph।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. FOL কি Decision Tree দিয়ে পুরোটা করা যাবে?	না; some fixed decisions করা যায়, full relational chaining নয়।
Q2. Grandparent relation কত link?	দুটি parent edge।
Q3. Sibling কি shared parent ছাড়া infer হবে?	এই rule অনুযায়ী না।

Full Question Bank link: Q. 36–52

Q2 | A* Search এবং Uniform-Cost Behavior

THEORY A* Priority Queue-তে f(n)=g(n)+h(n) minimize করে। g(n)=Start→n actual cost; h(n)=Goal পর্যন্ত estimate। UCS শুধু g(n) দেখে। h=0 দিলে A* UCS-রূপে কাজ করে।

Algorithm / Working Steps

1. Weighted graph ও provided h dictionary তৈরি।
2. Start-এ g=0, f=h(Start); minimum f pop।
3. প্রতিটি next node-এর new_g=g+edgeweight calculate।
4. আগের best_g-এর চেয়ে ভালো হলে heap update।
5. Goal pop হলে path/cost return; h=0 দিয়ে compare।

EXPECTED OUTPUT Graph: S→A(2), S→B(4), A→C(2), A→D(5), B→D(1), C→G(5), D→G(3)। A* path S→B→D→G, cost=4+1+3=8। h=0 version-এও cost=8।

OUTPUT EXPLANATION Goal G-এ h(G)=0। Equal-cost alternative paths থাকলে tie/order-এ route বদলাতে পারে, তবে selected path cost lowest রাখার উদ্দেশ্য। A* trace-এ node,g,h,f আলাদা দেখায়।

GRAPH / TRACE Trace পড়া: minimum f; goal-এ f=g কারণ h(G)=0।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
Weighted graph-এ heuristic-guided optimal path under suitable conditions।	Heuristic poorly chosen হলে effort বেশি বা optimality risk; memory overhead।	GPS routing, robot planning।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. A* কেন UCS হয় h=0 দিলে?	f=g+0=g, তাই priority UCS-এর।
Q2. g(D) যদি S→B→D হয়?	4+1=5।
Q3. f(D) যদি h(D)=2 হয়?	g(D)+h(D)=5+2=7।

Full Question Bank link: Q. 103–138; 139; 336; 342

Q3 | Iris K-Means: Model Selection

THEORY K-Means unlabeled samples-কে K cluster-এ ভাগ করে। Assignment: closest centroid; update: per-cluster mean। এই experiment-এ Iris-এর first two sepal features নিয়ে K=2,3,4,5 try, Inertia ও Silhouette compare।

Algorithm / Working Steps

1. Iris first-two-feature matrix তৈরি (Sepal Length ও Width)।

2. প্রতিটি K-তে n_init=10, random_state=42 দিয়ে KMeans.fit।

3. Inertia ও Silhouette calculate করে table print।

4. Highest Silhouette-এর K select; centroids ও scatter plot।

EXPECTED OUTPUT K=2: inertia 58.2041, silhouette 0.4630। K=3: 37.0507, 0.4451। K=4: 27.9902, 0.4249। K=5: 20.9968, 0.4101। Selected K=2।

OUTPUT EXPLANATION K বাড়ালে inertia কমে, তাই inertia alone best K নয়। Tested candidates-এ K=2 highest silhouette। তিনটি known species থাকা মানেই unsupervised grouping-এর K=3 হবে না।

GRAPH / TRACE X-axis Sepal Length, Y-axis Sepal Width; color=cluster, X marker=centroid।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
Label ছাড়া grouping ও visualization।	K-তে নির্ভরতা; initial centroid, outlier ও feature choice-sensitive।	Customer segmentation, grouping।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. Iris class 3 হলেও K=2 কেন?	Only two sepal features-এ highest tested silhouette K=2।
Q2. Inertia কি কমলেই best K?	না, K বাড়লে সাধারণত কমে; silhouette/elbow দরকার।
Q3. Scatter-এ X কী চিহ্ন?	Centroids-এর marker।

Full Question Bank link: Q. 235–275; 321–325; 346–351

SET-LEVEL TRICKY VIVA A* এবং UCS-এর relation? উত্তর: A* f=g+h; all h=0 দিলে UCS behavior। Good admissible/consistent heuristic A*কে search guide করে।

SET 04 / PRACTICAL REVISION

Set 04 — Bidirectional Search + WEKA + Regression

এই Set-এর A, B, C—তিনটি experiment নিচে ধারাবাহিকভাবে দেওয়া হলো। প্রতিটি অধ্যায়ের শেষে sir-style reasoning question আছে।

Q1 | BFS, DFS ও Bidirectional Search

THEORY Bidirectional search Start ও Goal দুই দিক থেকে BFS চালিয়ে common node-এ meets। BFS shortest-depth; DFS depth-first। Directed graph-এ backward BFS reverse adjacency ব্যবহার করে।

Algorithm / Working Steps

1. Start P, Goal V এবং original adjacency graph।
2. BFS ও DFS থেকে paths/expansion counts record।
3. Forward BFS P থেকে, backward BFS V থেকে।
4. Meeting node পেলে two half paths join।
5. Neighbor order বদলে DFS path compare।

EXPECTED OUTPUT BFS P→Q→S→V (7 expansions); DFS P→Q→S→V (4); Bidirectional একই path (code count=3)। Q-এর children reversed করলে DFS P→Q→T→V হতে পারে।

OUTPUT EXPLANATION Bidirectional দুই search space divide করে। এখানে count কীভাবে গণনা হচ্ছে তা code definition-dependent; paths/visited order compare করার আগে metric বুঝবে। DFS adjacency order-sensitive।

GRAPH / TRACE Two arrows: P → … → meeting ← … ← V।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
Bidirectional উপযুক্ত graph-এ অনেক কম search effort।	Backward search ও two-frontier control প্রয়োজন।	Route finding, word ladder।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. Meeting Point কী?	Forward ও backward visited frontier-এর intersection।
Q2. Directed graph-এ reverse adjacency কেন?	Goal থেকে predecessors traverse করতে।
Q3. Q-এর neighbor order বদলালে DFS কী বদলায়?	First explored branch এবং selected path বদলাতে পারে।

Full Question Bank link: Q. 53–102; 321–342

Q2 | WEKA Explorer: J48 ও IBk

THEORY WEKA একটি GUI-based ML toolkit। J48 C4.5-based Decision Tree, IBk instance-based k-NN। ARFF format-এ @relation, @attribute, @data থাকে। Classify tab-এ 10-fold CV দিয়ে evaluate করা হয়।

Algorithm / Working Steps

1. WEKA Explorer → Preprocess → iris.arff load।
2. Class attribute হিসাবে class select।
3. Classify → trees.J48 → 10-fold CV → Start।
4. Classify → lazy.IBk; k=1,3,5 দিয়ে evaluation।
5. Accuracy, Confusion Matrix, classification metrics record।

EXPECTED OUTPUT Python helper শুধু iris.arff verify করে (150 samples, 5 attributes including class, প্রতি class 50)। Real J48/IBk accuracy WEKA GUI-তে চালিয়ে পাওয়া যায়; fixed numerical accuracy এখানে দাবি করা হয়নি।

OUTPUT EXPLANATION Cross-validation দশটি validation fold-এর average performance দেয়। Preprocessing ভুল হলে metric misleading হতে পারে।

GRAPH / TRACE WEKA: Preprocess → Classify → Choose J48/IBk → Cross-validation → Start।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
Code ছাড়া model comparison; quick interactive analysis।	Settings ও leakage ভুল হলে ফল বিভ্রান্তিকর; GUI automation কঠিন।	ML education, tabular classification।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. J48 আর IBk-এর মূল পার্থক্য?	J48 tree rules শেখে; IBk nearest instances ব্যবহার করে।
Q2. 10-fold CV-তে 150 sample হলে প্রতি split?	সমান folds-এ 135 train, 15 held-out।
Q3. Python script কেন accuracy দেয় না?	WEKA GUI task; script ARFF file শুধু validate করে।

Full Question Bank link: Q. 301–320; 321–325

Q3 | Linear Regression: Last Target Changed

THEORY Data X=[2,4,6,8,10,12], Y=[5,9,13,17,21,25] প্রথমে exact line y=2x+1। শেষ target 25→30 করে Ordinary Least Squares refit করে outlier/sensitivity দেখায়।

Algorithm / Working Steps

1. Original X,Y দিয়ে LinearRegression fit।
2. Slope, intercept, prediction at 15, R^2 print।

3. Last Y=30 করে modified model fit।

4. Parameters ও graph of original vs changed line compare।

EXPECTED OUTPUT Original m=2, c=1, pred(15)=31, R^2=1। Modified m≈2.3571, c≈−0.6667, R^2≈0.9703।

OUTPUT EXPLANATION Original points একই straight line-এ। Last Y পরিবর্তনে fitted line কিছুটা steep হয় এবং residual errors আসে, তাই R^2<1।

GRAPH / TRACE Original fitted line-এর ওপর points; changed model শেষ Y=30-এর কারণে সরে যায়।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
Linear trend interpretation খুব সহজ।	Outlier-sensitive; extreme extrapolation ঝুঁকিপূর্ণ।	Trend fitting, numerical forecasts।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. Original R^2=1 কেন?	সব points y=2x+1-এ; SSE=0।
Q2. X=15 prediction?	2×15+1=31।
Q3. Negative intercept কি ভুল?	না; fitted model-এর parameter, অর্থ contextual হতে পারে।

Full Question Bank link: Q. 206–234; 321–335

SET-LEVEL TRICKY VIVA Bidirectional কেন তিন node expand? উত্তর: দুইদিকের frontier overlap দ্রুত হয়েছে; code-এর expanded-count convention জেনে count বলতে হবে।

SET 05 / PRACTICAL REVISION

Set 05 — Three-Room Agent + Greedy/A* + Decision Tree

এই Set-এর A, B, C—তিনটি experiment নিচে ধারাবাহিকভাবে দেওয়া হলো। প্রতিটি অধ্যায়ের শেষে sir-style reasoning question আছে।

Q1 | Three-Room Cleaning Agent

THEORY Simple rule-based agent তিনটি room A,B,C clean করে। নির্দিষ্ট route A→B→C→A ধরে; current room dirty হলে Suck, সব room clean হলে NoOp।

Algorithm / Working Steps

1. A=Dirty,B=Clean,C=Dirty দিয়ে শুরু।
2. A Dirty হলে Suck।
3. B Clean হলে MoveRight হয়ে C।
4. C Dirty হলে Suck; সব clean হলে NoOp।

EXPECTED OUTPUT Actions: Suck at A → MoveRight to B → MoveRight to C → Suck at C → NoOp। Final all Clean।

OUTPUT EXPLANATION Agent প্রথমে dirty room clean করে, clean room-এ unnecessary sucking করে না। Fixed route A→B→C হওয়ায় optimal movement নিশ্চিত নয়।

GRAPH / TRACE A (dirty) → B (clean) → C (dirty) → all clean।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
খুব সহজ বহু-room extension।	Cyclic path অপ্রয়োজনীয় moves দিতে পারে।	Indoor cleaning robots।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. সব room শুরুতে clean হলে?	NoOp।
Q2. তিন-ঘরের ক্ষেত্রে route কেন দরকার?	Agent-কে কোন room-এ যাবে নির্ধারণ করতে হয়।
Q3. Memory না থাকলে?	Visited-room বা status ভুলে repeat হতে পারে।

Full Question Bank link: Q. 1–20

Q2 | Greedy Best-First vs A* Search

THEORY Greedy lowest heuristic h নির্বাচন করে, actual accumulated cost g উপেক্ষা করে। A* f=g+h ব্যবহার করে weighted path cost ও heuristic মিলিয়ে search করে।

Algorithm / Working Steps

1. Weighted graph ও heuristics define।
2. Greedy minimum h দিয়ে path বের করো।
3. A* minimum f=g+h দিয়ে path বের করো।
4. Final path/cost/expanded order compare।

EXPECTED OUTPUT Greedy: A→C→E→G, cost=3+2+4=9। A*: A→B→E→G, cost=2+2+4=8।

OUTPUT EXPLANATION Greedy-তে h(C)=4 < h(B)=5, তাই C আকর্ষণীয়; কিন্তু total cost 9। A* accumulated g যোগ করে cost 8-এর route বেছে নেয়।

GRAPH / TRACE Route-cost comparison: 9 vs 8।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
A* suitable heuristic-এ lowest-cost path; Greedy অনেক ক্ষেত্রে দ্রুত।	Greedy nonoptimal; A* memory-intensive।	Navigation, autonomous route planning।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. Greedy h দেখে কেন ভুল করতে পারে?	Start থেকে ইতিমধ্যে খরচ কত হলো তা উপেক্ষা করে।
Q2. এই run-এ কোনটা better?	Weighted minimum-cost মানদণ্ডে A* cost 8।
Q3. A* কি সবসময় দ্রুত?	না; graph/heuristic অনুযায়ী performance বদলায়।

Full Question Bank link: Q. 103–145

Q3 | Decision Tree: Depth Selection

THEORY DecisionTreeClassifier Iris classes predict করে। max_depth model complexity নিয়ন্ত্রণ করে: ছোট depth underfit; বেশি depth overfit করতে পারে। Tree threshold-based, তাই সাধারণত feature standardization প্রয়োজন হয় না।

Algorithm / Working Steps

1. Iris train/test split।
2. depth 1,2,3,4,None দিয়ে Trees train ও evaluate।
3. Train/test accuracy table plot।
4. Best tested depth select; over/underfitting ব্যাখ্যা।

EXPECTED OUTPUT Depth 1: train/test 66.67/66.67%। Depth 2: 97.14/88.89%। Depth 3: 98.10/97.78%। Depth 4: 99.05/88.89%। None: 100/93.33%। Selected depth=3।

OUTPUT EXPLANATION Depth 1 খুব সহজ; None training data পুরো fit করে কিন্তু test accuracy কম। Depth 3 এই fixed test split-এ highest 97.78%। আদর্শ tuning validation/CV দিয়ে করতে হবে।

GRAPH / TRACE Train accuracy depth-এর সঙ্গে বাড়ে; Test accuracy ওঠানামা করে।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
Explainable tree; scaling কম দরকার।	Deep tree unstable ও overfit।	Risk classification, decision support।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. Depth None কেন selected নয়?	Training 100% হলেও test 93.33%, depth 3-এ test 97.78%।
Q2. max_depth=1-এ underfitting কীভাবে বুঝবে?	Train ও test উভয় accuracy কম।
Q3. Decision Tree ও FOL এক?	না; learned feature splits বনাম symbolic logical facts/rules।

Full Question Bank link: Q. 182–205; 276–300; 344

SET-LEVEL TRICKY VIVA Greedy ও A* কোনটা ভালো? উত্তর: এই weighted minimum-cost problem-এ A* cost 8 < Greedy 9; কিন্তু সব graph-এ runtime এভাবে হবে না।

SET 06 / PRACTICAL REVISION

Set 06 — Eligibility Inference + Search + k-NN/Tree

এই Set-এর A, B, C—তিনটি experiment নিচে ধারাবাহিকভাবে দেওয়া হলো। প্রতিটি অধ্যায়ের শেষে sir-style reasoning question আছে।

Q1 | Exam Eligibility: Forward Chaining + Truth Table

THEORY Rules দিয়ে exam eligibility infer করা হয়: Registered→Student; Student→HasID; Student∧PaidFee→ExamEligible; ExamEligible→CanEnterExamHall। Implication P→Q কেবল P true/Q false হলে false।

Algorithm / Working Steps

1. Initial facts Registered দিয়ে চালাও।
2. Rules প্রয়োগ করে Student, HasID infer।
3. PaidFee থাকলে ExamEligible; তারপর CanEnterExamHall।
4. Two cases ও implication truth table print।

EXPECTED OUTPUT Case 1 (Registered only): Student ও HasID, কিন্তু ExamEligible নয়। Case 2 (Registered + PaidFee): ExamEligible, CanEnterExamHall-সহ derived facts।

OUTPUT EXPLANATION একটি AND-rule-এর সব premises লাগবে। Registered থাকা একা PaidFee প্রমাণ করে না। Truth table logic validation বোঝায়।

GRAPH / TRACE Registered→Student→HasID; Student AND PaidFee→ExamEligible→CanEnterExamHall।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
Explainable automated rule decisions।	Rules incompleteness ও misinformation সমস্যা।	University eligibility, loan screening।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. Registered মানেই Eligible?	না; Student AND PaidFee দরকার।
Q2. P→Q কখন false?	P=true, Q=false হলে।
Q3. PaidFee না থাকলে কী?	ExamEligible infer হবে না।

Full Question Bank link: Q. 21–35; 36–52

Q2 | BFS, DFS ও IDDFS on Unweighted Graph

THEORY একই graph-এ BFS breadth-wise, DFS depth-wise ও IDDFS repeated depth-limited search চালায়। Unit-cost graph-এ BFS/IDDFS shallowest goal পেতে পারে।

Algorithm / Working Steps

1. Start S, Goal G নির্ধারণ।
2. Queue, Stack ও IDDFS দিয়ে পৃথক search চালাও।
3. Expanded sequence ও found path print।
4. IDDFS কোন limit-এ success তা record।

EXPECTED OUTPUT BFS: S→A→C→G; expanded count 8। DFS: S→A→C→G; expanded count 4। IDDFS: একই path, depth limit 3।

OUTPUT EXPLANATION DFS প্রথম useful branch-এ goal পেয়েছে, তাই এই graph-এ expansion কম। IDDFS depth 0–3 explore করে।

GRAPH / TRACE Expanded trace ও final path আলাদা করে পড়তে হবে।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
অ্যালগরিদমগুলোর shallowest-path বনাম effort trade-off বোঝা যায়।	DFS shortest guarantee নেই; IDDFS repeat work করে।	Puzzle/state-space search।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. BFS বেশি expansion মানে ভুল?	না; level-wise completeness/shortest-depth behavior-এর অংশ।
Q2. IDDFS path কেন same?	Goal-এর shallowest depth 3, branch order-এ একই route।
Q3. DFS path অন্য হতে পারে?	হ্যাঁ, adjacency ordering বদলালে।

Full Question Bank link: Q. 53–102

Q3 | Iris: k-NN vs Decision Tree

THEORY একই 70/30 stratified Iris split-এ k-NN(k=5) ও DecisionTree(max_depth=3) evaluate করা হয়। Accuracy সমান হলেও কোন test sample misclassify হয়েছে তা আলাদা হতে পারে।

Algorithm / Working Steps

1. Iris split: 105 train, 45 test।
2. k-NN(k=5) ও DecisionTree(depth=3) fit।
3. Confusion matrix, accuracy, misclassified test-row positions বের।

4. StandardScaler + k-NN দিয়ে আবার compare।

EXPECTED OUTPUT k-NN accuracy 97.78%, wrong test-row position 42। Decision Tree accuracy 97.78%, wrong position 39। Scaled k-NN accuracy ≈91.11%।

OUTPUT EXPLANATION দুটি model-ই 45টির 44টি সঠিক হলেও ভুল test instances আলাদা। X_test-এর index position original Iris dataset-এর row ID নয়।

GRAPH / TRACE দুটি Confusion Matrix-এর diagonal মোট 44 হলেও off-diagonal cell ভিন্ন হতে পারে।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
একই data-তে complementary classifiers তুলনা করা যায়।	Small test set-এ small error shifts score বদলায়।	Species classification, medical triage research।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. Accuracy same মানে models same?	না, decision boundaries ও ভুল sample আলাদা।
Q2. Test Row Position 42 কি original Iris row 42?	না, X_test-এর 0-based index।
Q3. Scaling k-NN কেন বদলায়?	Distance metric-এর geometry বদলায়।

Full Question Bank link: Q. 146–205; 276–300; 343; 345; 355

SET-LEVEL TRICKY VIVA Accuracy সমান হলেও কেন two models আলাদা? উত্তর: দুটিই 44/45 correct হলেও ভুল rows ভিন্ন; model decision boundary ও error type আলাদা।

SET 07 / PRACTICAL REVISION

Set 07 — FOL Siblings + Greedy Heuristic + Scaled K-Means

এই Set-এর A, B, C—তিনটি experiment নিচে ধারাবাহিকভাবে দেওয়া হলো। প্রতিটি অধ্যায়ের শেষে sir-style reasoning question আছে।

Q1 | FOL Relations: Siblings and Grandchildren

THEORY Parent facts থেকে Grandparent, Grandchild ও Sibling relation বের করা হয়। Grandchild(x,z) এবং Grandparent(z,x) সম্পর্কিত inverse interpretation হতে পারে। Sibling একই common parent-এর distinct children।

Algorithm / Working Steps

1. Parent facts list থেকে relationship pairs তৈরি।
2. Parent→Parent chain match করে grandparent/child query।
3. Same parent-এর child pairs নিয়ে x≠y condition।
4. Known query true/false print।

EXPECTED OUTPUT Grandchildren_of(Rahman) → Rafi, Tania। Grandchildren_of(Hasan) → Samia। Siblings(Hasan,Nabila) → True। Siblings(Hasan,Hasan) → False।

OUTPUT EXPLANATION Parent relation থেকে দুই-step path-এ grandchild পাওয়া যায়। Self-sibling false কারণ two persons distinct হতে হবে।

GRAPH / TRACE Rahman → Hasan → Rafi; Rahman → Nabila → Tania।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
Symbolic relation-এর logical validation।	Incomplete facts-এ deduced relation অনুপস্থিত।	Family databases, genealogy।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. Self-sibling কেন false?	x≠y rule।
Q2. Grandparent ও Grandchild-এর relation?	একটি অন্যটির inverse role; ancestor vs descendant।
Q3. একজনের দুটি parent থাকলে sibling rule কী?	যেকোনো one common parent থাকলেই current rule-এ sibling।

Full Question Bank link: Q. 36–52

Q2 | Greedy Search with Misleading Heuristic

THEORY Greedy Best-First শুধু lowest h(n) দেখে। Heuristic ভুল/অপ্রাসঙ্গিক হলে অযথা branch expand হয়; final path একইও থাকতে পারে।

Algorithm / Working Steps

1. Original heuristic দিয়ে Greedy চালাও।
2. Modified h(A)=0, h(D)=20 করো।
3. Same graph-এ Greedy rerun।
4. Expanded order ও final path compare।

EXPECTED OUTPUT Original: S→C→F→G; expanded count 4। Modified: একই final path S→C→F→G, কিন্তু expanded count 5।

OUTPUT EXPLANATION h(A)=0 A-কে প্রাথমিকভাবে অতিরিক্ত attractive করে; পরে h(D)=20 দেখে search অন্য branch-এ সরে যায়। একটি অপ্রয়োজনীয় expansion।

GRAPH / TRACE Original expansions=4, modified=5; same path।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
Heuristic quality-এর প্রভাব হাতে-কলমে বোঝা যায়।	Greedy path optimal নয়; misleading heuristic effort বাড়ায়।	Heuristic route planning।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. Heuristic bad হলে path বদলাতেই হবে?	না; expanded nodes বাড়লেও path একই থাকতে পারে।
Q2. Greedy কি g দেখে?	Selection-এ না; শুধু h।
Q3. h(A)=0 মানেই A goal?	না; designer estimate 0 দিলেও A প্রকৃত Goal নয়।

Full Question Bank link: Q. 103–138

Q3 | K-Means: With and Without Feature Scaling

THEORY Four Iris features দিয়ে k=3 clustering একবার original units-এ এবং একবার standardized features-এ করা হয়। Scaling distance ও centroid location বদলায়।

Algorithm / Working Steps

1. Full 4-feature Iris data load।
2. Original KMeans(k=3) fit; inertia, silhouette, centers বের।
3. StandardScaler fit_transform তারপর scaled KMeans(k=3)।
4. Metrics compare, inverse_transform দিয়ে centers original cm-এ আনো।

EXPECTED OUTPUT Original: inertia≈78.8514, silhouette≈0.5528। Standardized: inertia≈139.8205, silhouette≈0.4599।

OUTPUT EXPLANATION Scaled/unscaled inertia numbers সরাসরি তুলনা ঠিক নয়—coordinate units আলাদা। Plot-এ first two dimensions দেখালেও actual clustering চার feature-এ।

GRAPH / TRACE 2D scatter কেবল 4D clustering-এর projection; সম্পূর্ণ cluster separation বোঝায় না।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
Feature scale sensitivity demonstrate; centroids understand।	Wrong comparison ও scaling choice quality কমাতে পারে।	Customer feature grouping।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. Scaled inertia বড় মানে clustering খারাপ?	সরাসরি বলা যায় না; unit আলাদা।
Q2. inverse_transform কেন?	Original units-এ centroid দেখাতে।
Q3. Plot-এ 2 features, model-এ কত?	4 features।

Full Question Bank link: Q. 235–275; 326–329; 346–351

SET-LEVEL TRICKY VIVA Scaling করলে Inertia কেন বদলে গেল? উত্তর: Feature coordinate scale/metric পরিবর্তিত, তাই squared distances নতুন units-এ; direct compare করা ঠিক নয়।

SET 08 / PRACTICAL REVISION

Set 08 — DLS/IDDFS + WEKA + Train/Test Regression

এই Set-এর A, B, C—তিনটি experiment নিচে ধারাবাহিকভাবে দেওয়া হলো। প্রতিটি অধ্যায়ের শেষে sir-style reasoning question আছে।

Q1 | DLS ও IDDFS: Another Graph

THEORY Depth-limited DFS-এর cutoff ধারণা ও IDDFS-এর repeated depth limit নতুন graph-এ demonstrate। Goal root থেকে 3 edge দূরে।

Algorithm / Working Steps

1. Start A, Goal G।
2. DLS limit=2 run করে cutoff observe।
3. DLS limit=3 দিয়ে goal path।
4. IDDFS limit 0–3 run, root visits print।

EXPECTED OUTPUT DLS limit=2 → cutoff। DLS limit=3 → A→C→F→G, success। IDDFS same path; root visited 4 times।

OUTPUT EXPLANATION F পর্যন্ত depth 2, কিন্তু G depth 3। নতুন limit ছাড়া child G expand করা যায় না।

GRAPH / TRACE A → C → F → G (depth 0,1,2,3)।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
Depth cap ও unknown goal depth বোঝায়।	Repeat upper-level work।	Maze, limited puzzle solving।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. Limit=2-এ F পেলেও G কেন নয়?	F depth 2; G depth 3।
Q2. IDDFS root visits কত?	Limit 0–3 চারবার।
Q3. DLS limit 4 দিলে?	Goal আগে depth 3-এ পেলে success; অতিরিক্ত level পর্যন্ত যাওয়ার প্রয়োজন নেই।

Full Question Bank link: Q. 86–97

Q2 | WEKA Preprocessing + IBk/J48

THEORY WEKA Explorer-এ ARFF load, missing-value handling, normalization/standardization choice, class selection এবং IBk/J48 তুলনা করা হয়। Distance-based IBk scaling-sensitive, J48 সাধারণত নয়।

Algorithm / Working Steps

1. Preprocess tab-এ iris.arff load ও attributes inspect।
2. প্রয়োজনে ReplaceMissingValues, Normalize/Standardize filter।
3. Class attribute select।
4. Classify tab-এ IBk ও J48; same evaluation protocol 10-fold CV।
5. Accuracy, Confusion Matrix ও interpretation record।

EXPECTED OUTPUT Python helper class distribution/ARFF validation করে; actual J48 ও IBk result WEKA GUI থেকে নিতে হবে। একই 150 Iris instances, 3 classes।

OUTPUT EXPLANATION Preprocessing method training fold-এর statistics দিয়ে fit না করলে leakage হতে পারে। GUI output record করার আগে split/method জানা জরুরি।

GRAPH / TRACE Preprocess → Filter → Select class → Classify → 10-fold CV → Evaluate।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
GUI-based experimentation, fast comparison।	Wrong filter order বা configuration ফল misleading করে।	Data-mining preprocessing, classroom model comparison।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. IBk কি J48-এর মতো Tree শেখে?	না; nearest-instance distance দিয়ে predict।
Q2. Normalize বনাম Standardize?	Normalize range reshape; standardize z-score।
Q3. Cross-validation-এর আগে full data scale নিরাপদ?	না, leakage হতে পারে; CV fold অনুযায়ী fit উত্তম।

Full Question Bank link: Q. 301–320; 326–329

Q3 | Linear Regression: Train/Test Split

THEORY 16 synthetic study-hours/score samples-এ 75/25 split করে LinearRegression train, R^2 train/test এবং unseen hours prediction করা হয়। Small test size হলে reported R^2 volatile হতে পারে।

Algorithm / Working Steps

1. 16 records; train 12, test 4 split।
2. LinearRegression().fit on train only।

3. Slope/intercept ও R^2(train/test) calculate।

4. X=7.5 এবং X=18 predict; scatter + fitted line plot।

EXPECTED OUTPUT Slope≈4.0211, intercept≈11.9432। Train R^2≈0.9806; Test R^2≈0.9909। Pred(7.5)≈42.101; Pred(18)≈84.323।

OUTPUT EXPLANATION Slope প্রায় 4 মানে প্রতি extra study-hour-এ predicted score প্রায় 4 unit বেশি। 18 hours training range 1–16-এর বাইরে, তাই extrapolation। Test R^2 বেশি হতে পারে।

GRAPH / TRACE Scatter: train/test points আলাদা marker; fitted line।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
Train/test generalization বুঝতে সাহায্য করে।	মাত্র 4 test sample; extrapolation risk।	Score/price trend estimation।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. Training R^2< Test R^2 সম্ভব?	হ্যাঁ; ছোট test set বা সহজ test points।
Q2. 18-hour prediction কেন risky?	Observed hours range-এর বাইরে।
Q3. Intercept≈11.94 মানে?	X=0 হলে predicted value—কিন্তু observed range-এর বাইরে interpret সতর্ক।

Full Question Bank link: Q. 206–234; 330–335

SET-LEVEL TRICKY VIVA Test R^2 train-এর চেয়ে বেশি কেন? উত্তর: Test set মাত্র 4 samples এবং তুলনামূলক সহজ points থাকতে পারে; এটি কোনো guarantee নয়।

SET 09 / PRACTICAL REVISION

Set 09 — Adjacency Order + A* Admissibility + K-Means

এই Set-এর A, B, C—তিনটি experiment নিচে ধারাবাহিকভাবে দেওয়া হলো। প্রতিটি অধ্যায়ের শেষে sir-style reasoning question আছে।

Q1 | BFS/DFS: Adjacency Ordering

THEORY Neighbor list order-এ BFS/DFS node expansion sequence এবং multiple-solution path selection বদলায়। BFS equal-cost setting-এ shortest-edge length বজায় রাখে; DFS তা নিশ্চিত করে না।

Algorithm / Working Steps

1. Original adjacency order-এ BFS ও DFS run।
2. Expanded sequence ও paths record।
3. সব adjacency order reverse।
4. BFS/DFS আবার চালিয়ে result compare।

EXPECTED OUTPUT Original BFS A→B→E→G (3 edges), DFS A→B→D→H→G (4)। Reversed BFS A→C→F→G (3), DFS A→C→F→G (3)।

OUTPUT EXPLANATION BFS উভয় ordering-এ minimum 3-edge path পায়; tie-path বদলায়। DFS preferred branch অনুযায়ী path length 4→3 হয়েছে।

GRAPH / TRACE Original vs reversed adjacency-তে BFS shortest edge=3।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
Neighbor ordering-এর practical impact বুঝতে সাহায্য।	DFS output order-sensitive; sample graph ছাড়া universal conclusion নয়।	Graph traversal, maze。

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. BFS path বদলিয়ে length same কেন?	সমান depth-এ multiple goals/routes থাকতে পারে।
Q2. DFS original 4 edges কেন?	First explored branch 4-edge route।
Q3. Ordering কি A*কেও affect করে?	Equal f ties থাকলে কিছু ক্ষেত্রে expansion order বদলাতে পারে।

Full Question Bank link: Q. 53–85; 143–145

Q2 | A*: Heuristic Admissibility

THEORY A*-এ admissible heuristic true minimum remaining cost overestimate করে না; consistency triangle-style inequality বজায় রাখে। ভুল h(A) optimal result নষ্ট করতে পারে।

Algorithm / Working Steps

1. Original graph + heuristic দিয়ে A*।
2. Path/cost record।
3. h(A)=100 করে heuristic intentionally overestimate করো।
4. A* rerun, new path/cost compare।

EXPECTED OUTPUT Admissible h: S→A→D→G, cost=1+4+2=7। Modified h(A)=100: S→B→D→G, cost=5+1+2=8।

OUTPUT EXPLANATION A-এর true remaining minimum cost 6-এর কাছাকাছি হলেও h(A)=100 overestimate; A* branch A defer করে suboptimal cost=8 route complete করে।

GRAPH / TRACE Optimal route 7 বনাম modified heuristic route 8।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
Heuristic design-এর importance হাতে-কলমে বোঝায়।	Wrong heuristic graph-search optimality নষ্ট করে।	Path planning, routing।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. Admissible ও consistent same?	না; consistency বেশি strong।
Q2. Cost 7 কীভাবে?	1+4+2।
Q3. h(A)=100 কেন dangerous?	True remaining cost-এর বড় overestimate।

Full Question Bank link: Q. 103–138; 141

Q3 | K-Means: Elbow, Inertia এবং Silhouette

THEORY K-Means-এর K selection-এ Elbow ও Silhouette compare। Inertia হলো within-cluster squared error; k বাড়লে কমে। Silhouette cluster separation score; tested k≥2-এ ব্যবহার।

Algorithm / Working Steps

1. Sepal Length ও Width feature select।
2. k=2,3,4,5 দিয়ে KMeans fit।
3. Inertia table + elbow line plot।
4. Silhouette table/plot, best k নির্বাচন।

5. Selected clustering-এর centers/scatter দেখাও।

EXPECTED OUTPUT Same first-two-feature Iris settings-এ Set 03-এর মতো highest silhouette≈0.4630 at k=2। Inertia k বাড়লে 58.2041→37.0507→27.9902→20.9968।

OUTPUT EXPLANATION Elbow যেখানে decrease rate কমতে থাকে তা দেখে candidate K; Silhouette-এ maximum tested score k=2। Actual species count আলাদা বিষয়।

GRAPH / TRACE Elbow: X=k, Y=inertia। Silhouette: X=k, Y=score।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
Visual K selection; compactness/separation reasoning।	Elbow অস্পষ্ট হতে পারে; silhouette perfect criterion নয়।	Segmentation, exploratory grouping।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. Elbow সর্বনিম্ন inertia point?	না; bend/plateau onset দেখে।
Q2. Silhouette k=1 হয়?	না; at least two clusters লাগে।
Q3. k=2 selected কেন?	Tested values-এ সর্বোচ্চ silhouette।

Full Question Bank link: Q. 235–275; 349–351

SET-LEVEL TRICKY VIVA h(A)=100 করার ফল কী? উত্তর: Heuristic overestimate করে optimal branch postpone করে; ফলে cost 7-এর বদলে 8 হতে পারে।

SET 10 / PRACTICAL REVISION

Set 10 — Knowledge-Based Agent + BFS/Greedy/A* + Metrics

এই Set-এর A, B, C—তিনটি experiment নিচে ধারাবাহিকভাবে দেওয়া হলো। প্রতিটি অধ্যায়ের শেষে sir-style reasoning question আছে।

Q1 | Integrated Knowledge-Based Agent

THEORY Knowledge-based smart fan agent environment facts ও production rules দিয়ে FanOn infer করে। TemperatureHigh→Hot; Hot∧Humid→Uncomfortable; Uncomfortable→FanOn; Rain→Humid।

Algorithm / Working Steps

1. Rules ও initial facts set করা।
2. Forward Chaining দিয়ে Hot/Humid infer।
3. Both Hot এবং Humid থাকলে Uncomfortable derive।
4. Uncomfortable থাকলে FanOn এবং resulting state print।

EXPECTED OUTPUT TemperatureHigh only → Hot, FanOn=False। TemperatureHigh+Humid → FanOn=True। TemperatureHigh+Rain → Rain→Humid, Hot+Humid→Uncomfortable→FanOn=True।

OUTPUT EXPLANATION Indirect inference: Rain নিজে সরাসরি FanOn নয়, Humid infer করে; তারপর conjunction satisfiy হয়।

GRAPH / TRACE TemperatureHigh→Hot; Rain→Humid; Hot∧Humid→Uncomfortable→FanOn।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
Explainable smart automation।	Fixed rule environmental uncertainty handle করতে পারে না।	Smart fan, building climate automation।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. Rain fact থাকলেই FanOn?	TemperatureHigh/Hot-ও লাগবে।
Q2. Asserted vs inferred fact?	Asserted initial input; inferred rule দিয়ে পাওয়া।
Q3. Rule order বদলালে result বদলায়?	Exhaustive monotonic forward chaining শেষে same closure দেয়; trace order বদলাতে পারে।

Full Question Bank link: Q. 21–35; 51–52

Q2 | BFS, Greedy ও A*: Weighted Path Comparison

THEORY Same weighted graph-এ BFS shortest edge count, Greedy lowest h, A* lowest g+h দিয়ে path নির্বাচন করে। Shortest-edge count ও minimum actual cost আলাদা মানদণ্ড।

Algorithm / Working Steps

1. Weighted graph ও heuristic define।
2. BFS, Greedy, A* আলাদা run।
3. Paths এবং edge weights যোগ করে total cost calculate।
4. Which best for weighted least-cost objective explain।

EXPECTED OUTPUT BFS S→A→C→G, cost=1+9+7=17। Greedy S→A→D→G, cost=1+8+2=11। A* S→B→D→G, cost=2+1+2=5।

OUTPUT EXPLANATION তিনটিই 3-edge path হতে পারে; cost 17,11,5 আলাদা। Weighted cheapest-route criterion-এ A* result cost=5 সেরা।

GRAPH / TRACE Costs: BFS 17 | Greedy 11 | A* 5।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
A* cost-aware; BFS shallowest path-এ robust; Greedy quick heuristic exploration।	BFS weighted-optimal নয়, Greedy nonoptimal; A* heuristic/memory requirements।	Delivery routing, GPS।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. BFS কি ভুল result দিয়েছে?	না; BFS minimum depth objective মেটায়, minimum weighted cost নয়।
Q2. Cost=5 কীভাবে?	2+1+2।
Q3. Greedy কেন 11?	Minimum h path, g উপেক্ষা।

Full Question Bank link: Q. 53–85; 103–145

Q3 | k-NN vs Decision Tree: Precision, Recall, F1

THEORY Same Iris split-এ k-NN(k=3) ও DecisionTree(depth=3) compare। Accuracy ছাড়াও per-class confusion matrix এবং macro-averaged Precision, Recall, F1 calculate করা হয়।

Algorithm / Working Steps

1. Stratified 70/30 Iris split।
2. k-NN(k=3), DecisionTree(max_depth=3) fit।
3. Test predictions ও confusion matrices।

4. Accuracy এবং precision_recall_fscore_support(average=macro) evaluate।

5. Accuracy তারপর Macro F1 দিয়ে preferred model বাছাই।

EXPECTED OUTPUT k-NN: Accuracy 95.56%, Macro P≈0.9608, R≈0.9556, F1≈0.9554; 2 mistakes। Decision Tree: Accuracy 97.78%, Macro P≈0.9792, R≈0.9778, F1≈0.9778; 1 mistake।

OUTPUT EXPLANATION Tree এই fixed split-এ সব reported metrics-এ এগিয়ে, তাই preferred। Macro averaging প্রতিটি class-কে equal importance দেয়। একটি split থেকে universal winner ঘোষণা ঠিক নয়।

GRAPH / TRACE Confusion Matrix-এর off-diagonal error ও Macro F1 compare করবে।

ADVANTAGE	DISADVANTAGE	REAL-LIFE USE
Accuracy ছাড়াও class-sensitive metrics compare।	Small 45-test-sample evaluation-এর uncertainty।	Medical multiclass classification, image labels।

Viva Practice — এই experiment থেকে

QUESTION	SHORT ANSWER
Q1. Macro Precision কী?	প্রতিটি class-এর precision-এর simple average।
Q2. 2 mistakes হলে accuracy?	(45−2)/45=95.56%。
Q3. সেরা model কি সব dataset-এ Tree?	না; এই split-এ Tree ভালো, অন্য data/parameter-এ বদলাতে পারে।

Full Question Bank link: Q. 146–205; 276–300; 321–355

SET-LEVEL TRICKY VIVA BFS path cost 17 হলেও A* 5 কেন? উত্তর: BFS edge-count shortest, A* accumulated weighted cost ও remaining estimate দেখে।

APPENDIX A | Full Viva Question Bank

আগের আলোচনার ১–৩৫৫ পর্যন্ত সমস্ত numbered Q&A এখানে সংরক্ষিত। Set-wise অধ্যায়ের "Full Question Bank link" ব্যবহার করে প্রয়োজনীয় বিষয় খুঁজে নাও।

Intelligent Agent ও Vacuum Cleaner | Q.1–20

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
1	Agent কী?	যে system environment থেকে percept নিয়ে action সম্পন্ন করে।
2	Intelligent Agent কী?	যে agent উপলব্ধ তথ্য অনুযায়ী যুক্তিসংগত বা rational action বেছে নিতে পারে।
3	Agent-এর কাজ কী?	Perceive → Decide → Act।
4	Sensor কী?	Environment থেকে তথ্য সংগ্রহের উপাদান; যেমন dirt sensor।
5	Actuator কী?	Agent-এর action বাস্তবে সম্পন্ন করার উপাদান; যেমন motor বা vacuum suction।
6	Agent Function কী?	Percept history থেকে action নির্ধারণের mapping।
7	Agent Program কী?	Agent function বাস্তবায়নের executable code।
8	Environment কী?	যে surrounding world-এ agent কাজ করে।
9	PEAS কী?	Performance Measure, Environment, Actuator, Sensor।
10	Performance Measure কেন লাগে?	Agent-এর কাজ কত ভালো হচ্ছে তা মূল্যায়নের জন্য।
11	Vacuum Cleaner-কে Intelligent Agent বলা হয় কেন?	এটি ঘরের অবস্থা দেখে Suck, Move বা NoOp action নেয়।
12	Simple Reflex ও Model-Based Agent-এর পার্থক্য কী?	Simple Reflex বর্তমান percept-এর rule ব্যবহার করে; Model-Based internal state/history রাখে।
13	Vacuum Agent কি Decision Tree দিয়ে করা যাবে?	কিছু simple condition Decision Tree-তে দেখানো যায়, কিন্তু fixed rule-এর জন্য if-else সহজ।
14	Vacuum Agent-এ Machine Learning লাগবেই?	না। Fixed rules দিয়েও কাজ হয়; শেখার সক্ষমতা চাইলে ML যোগ করা যায়।
15	NoOp কী?	No Operation; আর কোনো action প্রয়োজন নেই।

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
16	সব Room Clean হলে Agent কী করবে?	এই lab-এর agent NoOp return করে।
17	Agent-এর Memory না থাকলে কী সমস্যা?	আগের পরিষ্কার করা জায়গা ভুলে অপ্রয়োজনীয় movement করতে পারে।
18	দুই-ঘর ও তিন-ঘর Vacuum Agent-এর পার্থক্য?	তিন-ঘরে state ও movement-এর সংখ্যা বেশি, route পরিচালনা জটিল।
19	Rational Agent আর Perfect Agent কি এক?	না। Rational উপলব্ধ তথ্য দিয়ে expected performance বাড়ায়; ভবিষ্যৎ সবকিছু জানে না।
20	Vacuum Cleaner Agent-এর বাস্তব ব্যবহার?	Robot vacuum, automated cleaning এবং smart robotics।

Knowledge Base, Forward Chaining ও FOL | Q.21–52

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
21	Knowledge Base (KB) কী?	Facts এবং logical rules-এর সংগঠিত সংগ্রহ।
22	Fact কী?	জানা তথ্য, যেমন Rain বা Registered(Ali)।
23	Rule কী?	শর্ত থেকে সিদ্ধান্তের নিয়ম, যেমন Rain → WetGround।
24	Inference কী?	Known facts ও rules থেকে নতুন conclusion বের করা।
25	Forward Chaining কী?	Initial facts থেকে rules প্রয়োগ করে নতুন facts derive করা।
26	Backward Chaining কী?	Goal থেকে শুরু করে তা প্রমাণের প্রয়োজনীয় facts খোঁজা।
27	Forward Chaining Data-Driven কেন?	কারণ এটি known facts দিয়ে শুরু করে।
28	Backward Chaining Goal-Driven কেন?	কারণ কাঙ্ক্ষিত conclusion প্রথমে নির্ধারণ করা হয়।
29	Forward Chaining কি Decision Tree দিয়ে করা যায়?	কিছু নির্দিষ্ট decision Tree-এ করা যায়; chaining-এর iterative multi-rule inference সাধারণ Tree-এর কাজ নয়।
30	Forward Chaining কখন Stop করে?	নতুন fact আর যোগ না হলে, অথবা বিশেষ goal পাওয়া গেলে।
31	AND rule-এ একটি condition সত্য হলেই হবে?	না। Rule-এর সব required premise সত্য হতে হবে।
32	Conclusion আগে থেকেই KB-তে থাকলে কী করবে?	আবার যোগ করবে না; set/membership check দিয়ে duplicate এড়াবে।

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
33	Forward Chaining-এর Real-Life Use?	Expert system, eligibility checking, troubleshooting, rule automation।
34	Weather Case A-তে WearJacket নেই, B-তে আছে কেন?	Rain এবং Cold দুটোই লাগবে; A-তে Cold নেই, B-তে আছে।
35	Registered থাকলেই ExamEligible?	না। Set 06-এর rules অনুযায়ী PaidFee-ও প্রয়োজন।
36	First-Order Logic (FOL) কী?	Objects, predicates, relations, variables ও quantifiers দিয়ে logical information প্রকাশের formal system।
37	Predicate কী?	কোনো property বা relation প্রকাশ করে; যেমন Parent(Ali,Babu)।
38	Constant কী?	একটি নির্দিষ্ট ব্যক্তি বা object-এর নাম; যেমন Ali।
39	Variable কী?	বিভিন্ন object নির্দেশ করতে পারে এমন প্রতীক; যেমন x, y।
40	Quantifier কয় ধরনের?	প্রধানত Universal (∀) ও Existential (∃)।
41	Universal Quantifier কী?	∀x = সব x-এর জন্য।
42	Existential Quantifier কী?	∃x = অন্তত একটি x আছে।
43	Grandparent relation কীভাবে derive করি?	Parent(A,B) এবং Parent(B,C) থাকলে Grandparent(A,C)।
44	Sibling relation কীভাবে derive করি?	ভিন্ন দুই ব্যক্তির common parent থাকলে sibling relation infer করা যায়।
45	x != y কেন ব্যবহার করি?	একজন নিজেই নিজের sibling হওয়া ঠেকাতে।
46	FOL ও Propositional Logic-এর পার্থক্য?	FOL-এ object, relation, variable ও quantifier আছে; propositional logic-এ মূলত whole statements।
47	FOL বনাম Decision Tree—কোনটা ভালো?	Logical relation/inference-এ FOL; labeled dataset-এর predictive classification-এ Decision Tree।
48	FOL কি Machine Learning Algorithm?	না। এটি symbolic knowledge representation ও reasoning framework।
49	FOL-এ নতুন ব্যক্তি যোগ করলে কী হয়?	নতুন facts ও বিদ্যমান rules থেকে নতুন relation derive হতে পারে।
50	FOL-এর সীমাবদ্ধতা কী?	অনেক facts/rules পরিচালনা কঠিন; uncertainty handle করতে অতিরিক্ত ব্যবস্থা লাগে।

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
51	TemperatureHigh ও Rain থেকে FanOn কীভাবে?	TemperatureHigh→Hot, Rain→Humid, HotHumidUncomfortable , UncomfortableFanOn ।
52	Forward Chaining ও ML-এর পার্থক্য?	Chaining পূর্বনির্ধারিত rules ব্যবহার করে; ML data থেকে pattern শেখে।

Search Fundamentals, BFS ও DFS | Q.53–85

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
53	Search Algorithm কী?	Initial state থেকে goal state-এ solution/path খোঁজার পদ্ধতি।
54	State কী?	Problem-এর একটি নির্দিষ্ট অবস্থা।
55	Initial State কী?	যে state থেকে search শুরু।
56	Goal State কী?	যে state-এ পৌঁছানো উদ্দেশ্য।
57	Node কী?	Search structure-এর element, যাতে state, parent/path-cost ইত্যাদি থাকতে পারে।
58	Edge কী?	দুটি state/node-এর transition বা connection।
59	Edge Weight কী?	এক transition-এর cost, যেমন দূরত্ব/সময়/টাকা।
60	Path কী?	Start থেকে Goal পর্যন্ত connected state/node sequence।
61	Path Cost কী?	Path-এর সব edge cost-এর যোগফল।
62	Frontier কী?	Discover হয়েছে কিন্তু এখনো expand হয়নি এমন node/path-এর সংগ্রহ।
63	Visited Set কেন লাগে?	Cycle ও repeated expansions কমাতে।
64	Expanded Node কী?	যে node-এর successor পরীক্ষা করা হয়; কোনো code goal dequeue করাকেও trace-এ রাখে।
65	Generated Node কী?	Successor হিসেবে তৈরি বা frontier-এ যুক্ত করা node।
66	Complete Algorithm কী?	উপযুক্ত assumptions-এ solution থাকলে সেটি খুঁজে পাওয়ার নিশ্চয়তা থাকে।
67	Optimal Algorithm কী?	Lowest-total-cost solution খুঁজে দেয়।

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
68	Informed ও Uninformed Search কী?	Informed heuristic ব্যবহার করে; uninformed heuristic ছাড়া exploration করে।
69	BFS-এর Full Form?	Breadth-First Search।
70	DFS-এর Full Form?	Depth-First Search।
71	BFS কোন Data Structure ব্যবহার করে?	FIFO Queue।
72	DFS কোন Data Structure ব্যবহার করে?	LIFO Stack বা recursion।
73	BFS কীভাবে কাজ করে?	Level-by-level node explore করে।
74	DFS কীভাবে কাজ করে?	এক branch গভীরে যায়, dead end হলে backtrack করে।
75	BFS কেন shortest path দেয়?	Equal-edge-cost graph-এ increasing depth explore করে, তাই minimum-edge path পায়।
76	DFS কেন shortest path নিশ্চিত নয়?	গভীর branch-এ goal আগে পেলে shorter branch পরে থাকতে পারে।
77	DFS কি BFS-এর চেয়ে দ্রুত?	সবসময় নয়; graph ও neighbor ordering-এর ওপর নির্ভর করে।
78	BFS-এর প্রধান অসুবিধা?	Frontier বড় হলে memory consumption বেশি।
79	DFS-এর প্রধান সুবিধা?	Depth-first tree traversal-এ frontier memory তুলনামূলক কম লাগতে পারে।
80	DFS-এ Backtracking কী?	Dead end থেকে আগের decision point-এ ফিরে অন্য branch explore করা।
81	BFS কি weighted graph-এ cheapest path দেয়?	ভিন্ন edge weight হলে না; UCS/A* প্রয়োজন হতে পারে।
82	DFS কি Infinite Loop-এ পড়তে পারে?	হ্যাঁ, visited checking/limit ছাড়া cycle বা infinite branch থাকলে।
83	BFS ও DFS কি একই path দিতে পারে?	হ্যাঁ, যেমন Set 01 ও Set 06-এ।
84	DFS code-এ reversed() কেন?	Stack-এ reverse push করে প্রথম listed neighbor আগে explore করাতে।
85	Neighbor ordering বদলালে output বদলায় কেন?	Explore করার priority/sequence বদলায়; DFS/BFS-এর tie-path বদলাতে পারে।

DLS, IDDFS ও Bidirectional Search | Q.86–102

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
86	DLS-এর Full Form?	Depth-Limited Search।
87	DLS কেন ব্যবহার করি?	DFS-কে নির্দিষ্ট depth-এর মধ্যে সীমাবদ্ধ রাখতে।
88	Depth Limit কী?	Root থেকে সর্বোচ্চ search depth।
89	DLS-এর তিনটি status কী?	Success, Cutoff, Failure।
90	Cutoff কী?	Limit-এর কারণে deeper exploration করা হয়নি।
91	Cutoff ও Failure আলাদা কেন?	Cutoff-এ limit-এর বাইরে goal থাকতে পারে; failure-এ পরীক্ষিত subtree-তে সম্ভাবনা ফুরিয়েছে।
92	IDDFS-এর Full Form?	Iterative Deepening Depth-First Search।
93	IDDFS কীভাবে কাজ করে?	Depth limit 0,1,2... দিয়ে repeated DLS চালায়।
94	IDDFS কেন Root বারবার visit করে?	প্রতিটি নতুন depth limit-এ root থেকে শুরু করে।
95	IDDFS ও BFS-এর common advantage?	Unit-cost search-এ shallowest solution।
96	IDDFS ও DFS-এর common advantage?	Depth-first traversal-এর তুলনামূলক কম memory।
97	DLS কি solution miss করতে পারে?	হ্যাঁ, goal depth limit-এর বাইরে হলে।
98	Bidirectional Search কী?	Start ও Goal থেকে দুই search চালিয়ে মাঝখানে মিলিত করা।
99	Bidirectional দ্রুত হতে পারে কেন?	উভয় দিক প্রায় d/2 depth explore করায় কিছু ক্ষেত্রে O(b^(d/2)) effort।
100	Meeting Point কী?	Forward ও backward search-এর common node।
101	Directed graph-এ backward search কীভাবে?	Original graph-এর reverse edges দিয়ে।
102	Bidirectional Search-এর অসুবিধা?	Goal জানা, backward traversal ও দুটি frontier পরিচালনা প্রয়োজন।

UCS, Greedy, A*, Heuristics ও Set Output | Q.103–145

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
103	UCS-এর Full Form কী?	Uniform-Cost Search।
104	UCS কোন value দেখে?	Lowest accumulated actual path cost g(n)।

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
105	Greedy Best-First কী দেখে?	Estimated remaining cost h(n)।
106	A* কোন value দেখে?	f(n)=g(n)+h(n)।
107	g(n) কী?	Start থেকে বর্তমান node n পর্যন্ত actual path cost।
108	h(n) কী?	বর্তমান node থেকে goal পর্যন্ত estimated remaining cost।
109	f(n) কী?	Start→Goal-এর estimated total solution cost via node n।
110	g(Start) কত?	সাধারণত 0।
111	h(Goal) কত?	সাধারণত 0।
112	A* কি UCS-এর কাজ করতে পারে?	হ্যাঁ, সব h(n)=0 হলে A* UCS-এর মতো।
113	UCS ও Greedy কি একই?	না। UCS g(n), Greedy h(n) minimize করে।
114	Greedy কি optimal?	সাধারণভাবে না।
115	A* কি সবসময় optimal?	না। Heuristic admissibility/consistency এবং graph-search implementation-এর শর্ত প্রয়োজন।
116	Priority Queue কেন ব্যবহার করি?	Minimum priority score-এর entry আগে নেওয়ার জন্য।
117	Greedy-তে g(n) print করলেও নির্বাচন কীভাবে?	Selection শুধু h(n) দিয়ে হয়; g(n) প্রদর্শন করা যেতে পারে।
118	A* বেশি Memory নেয় কেন?	Frontier ও best-cost entries অনেক রাখতে হয়।
119	Greedy কখন ভালো কাজ করে?	Heuristic goal-দিকটি ভালো নির্দেশ করলে।
120	Negative edge cost UCS/A* কি নিরাপদ?	Standard optimality guarantee সাধারণত থাকে না; problem-specific algorithm প্রয়োজন।
121	h(n)-এর value কোথা থেকে আসে?	Problem-specific estimate বা designer-provided heuristic; distance/relaxation দিয়ে হিসাব করা যায়।
122	Euclidean Distance কখন ব্যবহার?	Coordinates-এ straight-line distance meaningful lower-bound হলে।
123	Manhattan Distance কখন ব্যবহার?	Unit-cost four-directional grid movement-এ।
124	Admissible Heuristic কী?	কখনো true minimum remaining cost overestimate করে না: h(n)≤h*(n)।
125	Consistent Heuristic কী?	প্রতিটি edge-এ h(n)≤c(n,n')+h(n') মানে।
126	Admissible কিন্তু Inconsistent হতে পারে?	হ্যাঁ; consistency আরও শক্তিশালী constraint।

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
127	h(n) যত ছোট তত ভালো?	না। খুব দুর্বল heuristic কম guide করে; admissible-এর মধ্যে বেশি informative estimate কার্যকর।
128	h(n)=0 হলে ভুল?	না। Nonnegative-cost graph-এ A* UCS-এর মতো হয়।
129	h(n) কি negative হতে পারে?	সাধারণ remaining-cost heuristic nonnegative রাখা হয়।
130	h(n) খুব বেশি দিলে কী হয়?	Overestimate করলে A* suboptimal হতে পারে।
131	Misleading Heuristic কী?	যে heuristic search-কে কম উপকারী branch-এর দিকে guide করে।
132	Set 07-এ h(A)=0 ও h(D)=20 কেন?	Greedy প্রথমে A expand করে পরে C branch নেয়—extra expansion দেখাতে।
133	Set 09-এ h(A)=100 করলে cost কেন বাড়ে?	অতিরঞ্জিত h কম-cost branch-কে discourage করে; test graph-এ cost 7→8।
134	A* একই node-এ দুই route পেলে কী করে?	নতুন g কম হলে best_g update করে route improve করে।
135	best_g কেন?	প্রতি node-এ এখন পর্যন্ত lowest known cost মনে রাখতে।
136	Stale Entry কী?	Priority queue-তে থাকা obsolete higher-cost entry; code skip করে।
137	A* কি শুধু Goal-এর কাছে থাকা node নেয়?	না। g+h দুটো দেখে।
138	Equal f(n) হলে tie কীভাবে resolve?	Implementation tie-breaker, যেমন increasing counter।
139	Set 03-এ A* cost 8 কীভাবে?	S→B→D→G: 4+1+3=8।
140	Set 05-এ Greedy 9 ও A* 8 কেন?	Greedy h দেখে A→C→E→G, A* g+h দেখে A→B→E→G।
141	Set 09-এ h(A)=100 দিলে কী?	A* cost 7-এর পরিবর্তে 8-এর path নিতে পারে।
142	Set 10-এ BFS 17 কিন্তু A* 5 কেন?	BFS minimum-edge depth দেখে, A* weighted total cost বিবেচনা করে।
143	Set 01-এ DFS কম expansion করলে সবসময় ভালো?	না। Shortest-path guarantee নেই; result ordering-dependent।
144	Set 09-এ adjacency বদলে BFS path পাল্টালেও ঠিক কেন?	Minimum-depth goal-এর একাধিক path থাকতে পারে।
145	Weighted graph-এ কোন search বেছে নেবে?	Cheapest path চাইলে UCS; suitable admissible heuristic থাকলে A*।

Machine Learning, Iris Dataset ও k-NN | Q.146–181

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
146	Machine Learning কী?	Data থেকে pattern শিখে prediction/decision নেওয়ার computational methods।
147	AI ও ML-এর পার্থক্য?	AI বড় intelligent-system ক্ষেত্র; ML data-driven learning-এর উপক্ষেত্র।
148	Supervised Learning কী?	Labeled data দিয়ে mapping শেখানো।
149	Unsupervised Learning কী?	Unlabeled data থেকে structure/pattern/group বের করা।
150	Reinforcement Learning কী?	Reward/feedback দিয়ে action policy শেখা।
151	Classification কী?	Category/class predict করা।
152	Regression কী?	Continuous numerical target predict করা।
153	Feature কী?	Model-এর input attribute/variable।
154	Target বা Label কী?	Predict করার output।
155	Training কী?	Training data থেকে model parameters বা structure শেখা।
156	Testing কী?	Held-out unseen data দিয়ে performance evaluate করা।
157	Iris Dataset-এ কয়টি sample?	মোট 150টি।
158	Iris Dataset-এর চার feature?	Sepal Length, Sepal Width, Petal Length, Petal Width।
159	Iris Dataset-এ কয়টি class?	তিনটি—Setosa, Versicolor, Virginica।
160	Iris Dataset-এ প্রতি class sample?	50টি।
161	k-NN কী?	Supervised distance-based method; nearest k training samples দিয়ে classify করে।
162	k-NN-এর Algorithm কী?	Distance calculate → k nearest select → majority vote/prediction।
163	k-NN-এ k কী?	কয়টি training neighbor ব্যবহার করবে।
164	k-NN কি Clustering?	এই experiment-এ না; এটি supervised classification।
165	k-NN-কে Lazy Learner কেন?	Training-এ সাধারণত samples সংরক্ষণ করে; prediction-এ neighbors খোঁজে।
166	k-NN Distance কীভাবে?	সাধারণ Euclidean: sqrt(Σ(x_i−y_i)²)।

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
167	Nearest Neighbor কী?	Distance অনুযায়ী সবচেয়ে কাছের training sample।
168	k=3 কীভাবে class দেবে?	তিন nearest sample-এর majority class নেয়, যেমন Setosa, Setosa, Virginica→Setosa।
169	k=1 রাখলে সমস্যা?	এক noisy sample decision-এ বেশি প্রভাব ফেলে।
170	k অনেক বড় রাখলে সমস্যা?	দূরের ভিন্ন class-এর vote এসে underfitting হতে পারে।
171	Best k কীভাবে select করি?	Training data-তে cross-validation দিয়ে candidate k compare করে।
172	k=3,5,7—কোনটা ভালো?	Validation performance ভালো যেটি; স্থির কোনো universal k নেই।
173	k সবসময় odd রাখতে হবে?	না; binary tie কমাতে odd সহায়ক, multiclass-এও tie হতে পারে।
174	k-NN-এ Scaling কেন লাগে?	বড়-scale feature distance dominate করতে পারে।
175	Scaling করলে Accuracy সবসময় বাড়ে?	না; Set 01-এর particular split-এ কমেছিল।
176	Standardization কী?	z=(x−μ)/σ; training distribution-এ mean 0, std 1 scale।
177	Normalization ও Standardization এক?	না। Min-Max সাধারণত [0,1]; standardization z-score।
178	কোন model-এ feature scaling কম জরুরি?	Decision Tree-এর মতো threshold-splitting model।
179	k-NN-এর Advantages?	সহজ, multiclass, অল্প training computation।
180	k-NN-এর Disadvantages?	Prediction time/storage বেশি; scale ও irrelevant/noisy feature-sensitive।
181	k-NN-এর Real-Life Uses?	Pattern recognition, classification, similarity-based recommendation।

Decision Tree | Q.182–205

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
182	Decision Tree কী?	Feature-based questions/splits দিয়ে classification বা regression model।
183	Decision Tree-এর অংশ?	Root, Internal Decision Node, Leaf।
184	Root Node কী?	Tree-এর প্রথম split/decision node।

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
185	Leaf Node কী?	যেখানে final predicted class বা value থাকে।
186	Decision Tree কীভাবে split করে?	Gini/Entropy বা regression impurity কমায় এমন threshold select করে।
187	Gini Impurity কী?	$1-\Sigma p_i^2$; node-এ class mixing-এর measure।
188	Entropy কী?	$-\Sigma p_i \log_2(p_i)$; class uncertainty-এর measure।
189	Information Gain কী?	Parent entropy − weighted child entropy।
190	scikit-learn Decision Tree code-এ Gini নাকি Entropy?	criterion পরিবর্তন না করলে default Gini।
191	max_depth কী?	Tree-এর সর্বোচ্চ split depth।
192	max_depth=1 হলে কী হয়?	খুব simple tree; underfitting হতে পারে।
193	max_depth=None হলে কী?	Explicit depth cap নেই; other stopping rules পর্যন্ত grow করে।
194	Depth বেশি হলে accuracy সবসময় বাড়ে?	Training performance বাড়তে পারে, test performance নাও বাড়তে পারে।
195	Overfitting কী?	Training-এ ভালো কিন্তু unseen data-তে খারাপ generalization।
196	Underfitting কী?	Model প্রয়োজনীয় pattern ধরতে খুব simple।
197	Overfitting কমানোর উপায়?	Pruning, max_depth, min_samples_leaf, CV, বেশি representative data।
198	Set 05-এ Depth=3 কেন chosen?	এই holdout split-এ পরীক্ষা করা depth-গুলোর মধ্যে highest test accuracy; আদর্শ selection validation-এ।
199	Decision Tree-এর Advantages?	Interpretable rules; nonlinear interactions; scaling কম দরকার।
200	Decision Tree-এর Disadvantages?	Overfitting ও small data change-এ unstable structure।
201	Decision Tree-এর Real-Life Use?	Risk classification, loan decision support, categorization।
202	k-NN vs Decision Tree—কোনটা ভালো?	Dataset ও metric-নির্ভর; k-NN distance-based, Tree rule-based।
203	Decision Tree দিয়ে Regression হয়?	হ্যাঁ, DecisionTreeRegressor continuous target predict করে।

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
204	Decision Tree কি K-Means-এর মতো clustering?	সাধারণ classification Decision Tree supervised, K-Means unsupervised clustering।
205	k-NN-এর k আর K-Means-এর k?	k-NN neighbor count; K-Means cluster count।

Linear Regression | Q.206–234

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
206	Linear Regression কী?	Input features থেকে continuous target-এর linear relationship শেখার supervised model।
207	Linear Regression Supervised নাকি Unsupervised?	Supervised।
208	Regression Equation কী?	$\hat{y}=mx+c$ (single feature)।
209	Slope কী?	X এক unit বাড়লে predicted Y গড়ে কত বদলায়।
210	Intercept কী?	X=0 হলে predicted Y; extrapolation হলে বাস্তব ব্যাখ্যায় সতর্কতা।
211	Independent Variable?	Predictor/input X।
212	Dependent Variable?	Target/output Y।
213	Prediction কী?	নতুন input-এর জন্য fitted model-এর estimated output।
214	Fitted Line কী?	Data অনুযায়ী model শেখা line।
215	Actual vs Predicted Value?	Actual observed Y; Predicted model-estimated $\hat{y}$।
216	Residual কী?	Observed−Predicted: $e_i=y_i-\hat{y}_i$।
217	Least Squares কী?	Squared residual sum minimize করে parameters fit করা।
218	Slope ও Intercept কীভাবে calculate?	$m=\Sigma(x-\bar{x})(y-\bar{y})/\Sigma(x-\bar{x})^2$; $c=\bar{y}-m\bar{x}$।
219	R^2 Score কী?	1−SSE/SST; mean baseline-এর তুলনায় explained variation-এর measure।
220	$R^2=1$ মানে কী?	ঐ evaluation samples-এ perfect fit।
221	$R^2=0$ মানে কী?	Mean-based baseline-এর সমান squared-error fit।
222	R^2 Negative হতে পারে?	হ্যাঁ; mean baseline-এর চেয়ে খারাপ prediction হলে।

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
223	R^2 ও Accuracy একই?	না। R^2 regression, accuracy classification metric।
224	MAE, MSE, RMSE কী?	Mean Absolute Error, Mean Squared Error, Root Mean Squared Error।
225	একটি Y বাড়ালে কী হয়?	Fitted slope, intercept, predictions, R^2 বদলাতে পারে।
226	Set 04 Original R^2=1 কেন?	সব points y=2x+1 line-এ পুরোপুরি ছিল।
227	Set 04-এ X=15 Prediction?	2×15+1=31।
228	Set 04 Last Y 25→30 করলে?	Slope ≈ 2.3571, intercept ≈ −0.6667; R^2 কমে।
229	Negative Intercept মানেই ভুল model?	না; তবে X=0-এর অর্থ ও training range বিবেচ্য।
230	Training R^2 vs Test R^2?	Training seen samples-এ, Test held-out samples-এ fit quality।
231	Test R^2 বেশি হতে পারে?	হ্যাঁ; split-এর composition বা small test set-এর কারণে।
232	Set 08-এ 18 Hours prediction সতর্ক কেন?	Observed hours range 1–16-এর বাইরে extrapolation।
233	Regression Graph-এর X/Y axis কী?	সাধারণত X=Study Hours; Y=Actual/Predicted Score।
234	Regression-এর Advantages/Disadvantages/Uses?	সহজ ও explainable; nonlinearity/outlier সমস্যা; sales, demand, score estimates।

K-Means Clustering | Q.235–275

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
235	Clustering কী?	Similar samples-গুলোকে unlabeled group-এ ভাগ করা।
236	K-Means কী?	Centroid-based unsupervised clustering algorithm।
237	K-Means Supervised নয় কেন?	Fitting-এ class label ব্যবহার করা হয় না।
238	K-Means-এ K কী?	Cluster-এর সংখ্যা।
239	Centroid কী?	Cluster-এর member points-এর mean vector।
240	Nearest Centroid কী?	যার সঙ্গে point-এর Euclidean distance সবচেয়ে কম।
241	K-Means কোন Distance ব্যবহার?	Standard K-Means squared Euclidean distance minimize করে।
242	K-Means Objective কী?	Within-cluster sum of squared distances minimize করা।

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
243	K-Means-এর প্রধান দুটি Step?	Assignment step, Centroid update step।
244	K-Means কখন Stop?	Centroids/assignments stabilise, tolerance বা max_iter limit এলে।
245	K-Means Output কী?	Cluster labels, centroids, inertia; evaluation score চাইলে separately calculate।
246	Cluster Label 0,1,2 কী?	Arbitrary cluster IDs; original class labels নয়।
247	Centroid কীভাবে calculate?	প্রতি coordinate-এর arithmetic mean, যেমন (2,4),(4,6),(6,8)→(4,6)।
248	Centroid কি actual point হতে হবে?	না, mean position data-তে নাও থাকতে পারে।
249	Mean কেন, Median নয়?	Squared Euclidean loss mean দ্বারা minimize হয়।
250	Inertia কী?	Assigned centroid থেকে sample-এর squared distances-এর যোগফল।
251	Inertia manual calculation?	Points 2,4,6; mean 4; inertia=4+0+4=8।
252	Inertia কি Negative?	না; squared distances nonnegative।
253	K বাড়ালে Inertia কমে কেন?	বেশি clusters দিয়ে within-cluster fit উন্নত করা সম্ভব; global optimum কখনো বাড়ে না।
254	Lowest Inertia মানেই Best K?	না; K খুব বড় হলেও inertia ছোট হয়, separation/meaningful grouping দেখতে হবে।
255	Best K কীভাবে বের করব?	Elbow, Silhouette, domain context, cluster stability।
256	Elbow Method কী?	Inertia decrease কোথায় উল্লেখযোগ্যভাবে ধীর হয়, সেই bend দেখে K নির্বাচন।
257	Silhouette Score কী?	নিজের cluster-এর compactness বনাম nearest other cluster separation measure।
258	Silhouette calculation কী?	s=(b−a)/max(a,b); a=2,b=6 হলে 4/6≈0.667।
259	Negative Silhouette মানে?	Point তার nearest other cluster-এর বেশি কাছাকাছি হতে পারে।
260	Silhouette Score Range?	−1 থেকে +1।

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
261	Silhouette বেশি হলেই true species মেলে?	না; geometric groups সবসময় domain labels-এর সঙ্গে মেলে না।
262	Iris-এ 3 species থাকা সত্ত্বেও Set 03-এ K=2 কেন?	First two sepal features-এ tested K-এর highest silhouette ছিল K=2।
263	K=1-এ Silhouette কেন নেই?	অন্য cluster লাগে; কমপক্ষে 2 distinct clusters প্রয়োজন।
264	Elbow ও Silhouette একই K দেয়?	সবসময় নয়; criteria আলাদা।
265	K-Means-এ Scaling কেন?	বড়-range feature distance dominate করতে পারে।
266	Set 07-এ Scaling করলে Inertia বদলায় কেন?	Coordinates/units ও point distances বদলায়।
267	Scaled/Unscaled Inertia তুলনাযোগ্য?	সরাসরি না; আলাদা units ও feature spaces।
268	inverse_transform() কেন?	Scaled centroids-কে original unit-এ ফেরত আনতে।
269	n_init=10 কী?	ভিন্ন 10 initialization চেষ্টা করে ভালো inertia solution নির্বাচন।
270	random_state=42 K-Means-এ কেন?	Random initialization reproducible রাখতে।
271	K-Means++ কী?	Well-spread initial centroids নির্বাচনের strategy।
272	Outlier K-Means-কে কীভাবে প্রভাবিত?	Squaring distant error centroid টেনে সরাতে পারে।
273	K-Means-এর Limitations?	K পূর্বনির্ধারণ; outlier/scale/init-sensitive; complex-shape clusters-এ সীমাবদ্ধতা।
274	K-Means Advantages?	সহজ, সাধারণত efficient, interpretable centroids।
275	K-Means Uses?	Customer segmentation, image color compression, numerical grouping।

Confusion Matrix ও Classification Metrics | Q.276–300

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
276	Confusion Matrix কী?	Actual vs predicted classes-এর count table।
277	TP কী?	Actual Positive এবং Predicted Positive।
278	TN কী?	Actual Negative এবং Predicted Negative।
279	FP কী?	Actual Negative হলেও Predicted Positive।

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
280	FN কী?	Actual Positive হলেও Predicted Negative।
281	Accuracy কী?	Correct predictions / total predictions।
282	Precision কী?	TP/(TP+FP); predicted positives-এর quality।
283	Recall কী?	TP/(TP+FN); actual positives-এর detection rate।
284	F1 Score কী?	Precision ও Recall-এর harmonic mean: 2PR/(P+R)।
285	Support কী?	Evaluation sample-এ একটি class-এর actual instances সংখ্যা।
286	Set 01 Accuracy কীভাবে?	Confusion Matrix diagonal=15+15+14=44, total=45; 44/45×100=97.78%।
287	Confusion Matrix Diagonal কী?	Correct prediction counts।
288	Diagonal-এর বাইরে সংখ্যা?	Misclassification counts।
289	Rows/Columns কী বোঝায়?	এই sklearn outputs-এ rows Actual, columns Predicted।
290	Precision calculation?	TP=8,FP=2 হলে P=8/(8+2)=80%।
291	Recall calculation?	TP=8,FN=4 হলে R=8/(8+4)=66.67%।
292	F1 calculation?	P=0.8,R=0.5 হলে F1=2×0.8×0.5/1.3≈0.6154।
293	Precision/Recall কোনটি বেশি গুরুত্বপূর্ণ?	False Positive কমাতে Precision; False Negative কমাতে Recall।
294	99% Accuracy হলেও খারাপ হতে পারে?	হ্যাঁ; class imbalance-এ majority baseline misleading।
295	Macro Average কী?	Per-class metrics-এর unweighted average।
296	Weighted Average কী?	Per-class support অনুযায়ী weighted average।
297	Micro Average কী?	সব class-এর TP/FP/FN aggregated করে metric।
298	Multiclass TP/FP কীভাবে?	একটি class-কে positive, অন্য class-গুলোকে negative ধরে One-vs-Rest।
299	Classification Report-এ কী?	Precision, Recall, F1, Support এবং averages।
300	Accuracy সমান হলেও model পার্থক্য?	ভিন্ন sample-এ error এবং per-class metrics আলাদা হতে পারে।

WEKA, J48, IBk ও Cross-Validation | Q.301–320

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
301	WEKA কী?	Waikato Environment for Knowledge Analysis—Java-based ML/Data Mining toolkit।
302	WEKA-তে GUI কোথায়?	Explorer-এর Preprocess ও Classify tab-এ।
303	ARFF কী?	Attribute-Relation File Format।
304	ARFF-এর sections কী?	@relation, @attribute, @data।
305	J48 কী?	WEKA-এর C4.5-based Decision Tree classifier।
306	IBk কী?	WEKA-এর instance-based k-NN classifier।
307	J48 vs IBk?	J48 learned tree rules; IBk nearest training instances ব্যবহার করে।
308	WEKA Class Attribute কী?	যে output label predict করতে হবে।
309	Preprocessing কী?	Training-এর আগে data clean/transform করা।
310	Missing Value কীভাবে handle?	Appropriate imputation, removal বা algorithm-specific method।
311	Normalization কেন?	Feature range differences নিয়ন্ত্রণ করতে।
312	J48-এর জন্য Scaling জরুরি?	সাধারণত না; threshold-based tree।
313	IBk-এর জন্য Scaling কেন?	Distance-based; feature range গুরুত্বপূর্ণ।
314	10-fold Cross-Validation কী?	10 ভাগ; প্রতি iteration 9 অংশ train, 1 অংশ evaluate।
315	150 samples, 10-fold হলে প্রতি iteration?	সমান folds হলে 135 training, 15 validation।
316	10-fold CV ও 70/30 Split এক?	না; CV-তে 10 evaluation folds, split-এ সাধারণত এক division।
317	WEKA Python script কি classifier accuracy দেয়?	না; Set 04-B/08-B scripts ARFF verify করে, J48/IBk GUI-তে চালাতে হয়।
318	WEKA vs scikit-learn accuracy কি same?	সবসময় নয়; split, preprocessing, parameters ও implementation ভিন্ন হতে পারে।
319	Data Leakage কী?	Training/model selection-এ validation/test information অনুচিতভাবে ঢুকে পড়া।

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
320	Cross-validation-এর আগে full data scale কেন risky?	Validation fold-এর statistics training preprocessing-এ ঢুকে যেতে পারে।

Python Code & Library Viva | Q.321–355

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
321	Python কেন ব্যবহার?	সহজ syntax ও ML ecosystem—NumPy/Pandas/sklearn/Matplotlib।
322	NumPy কী?	Array ও numerical operations library।
323	Pandas কী?	DataFrame ও tabular data processing library।
324	Matplotlib কী?	Data visualization/plotting library।
325	scikit-learn কী?	Python-এর ML model, preprocessing ও metric library।
326	fit() কী?	Training data দিয়ে model শেখানো।
327	predict() কী?	New input-এর predicted output return।
328	fit_transform() কী?	Transformer fit করে transformed data return।
329	transform() কী?	Fitted transformation নতুন data-তে প্রয়োগ।
330	train_test_split() কী?	Data-কে train/test subset-এ ভাগ।
331	test_size=0.30 কী?	30% samples test-এ।
332	stratify=y কেন?	Class proportions split-এ প্রায় বজায় রাখতে।
333	random_state=42 কেন?	Random operations reproducible রাখতে; 42 arbitrary seed।
334	reshape(-1,1) কেন?	Single-feature array-কে 2D sample-by-feature matrix করা।
335	model.score() কী?	Classifier-এর জন্য accuracy, LinearRegression-এর জন্য R^2।
336	heapq কী?	Python heap-based priority queue support।
337	deque কী?	Efficient queue operations-এর collection।
338	popleft() BFS-এ কেন?	Queue-এর সামনে থেকে efficient removal।

NO.	VIVA QUESTION	SIMPLE BANGLA ANSWER
339	stack.pop() কী?	Stack-এর last added element সরায় ও return করে।
340	seen=set() কেন?	Visited membership ও duplicates track করতে।
341	graph.get(node,[]) কেন?	Node-এর adjacency না থাকলে নিরাপদে empty list return।
342	count() search code-এ কেন?	Equal priority হলে deterministic tie-break counter।
343	np.flatnonzero() কী?	Nonzero বা True entries-এর index positions।
344	max_depth=3 কী?	Decision Tree-এর সর্বোচ্চ depth 3।
345	n_neighbors=5 কী?	k-NN-এ nearest 5 samples ব্যবহার।
346	n_clusters=3 কী?	K-Means দিয়ে 3 cluster তৈরি।
347	cluster_centers_ কী?	Fitted K-Means-এর centroid coordinates।
348	labels_ কী?	Training points-এর assigned cluster IDs।
349	inertia_ কী?	K-Means fitted objective: squared distances sum।
350	silhouette_score() কী?	Cluster compactness/separation calculate করে।
351	idxmax() কী?	Column/Series-এর maximum-এর index।
352	plt.scatter() vs plt.plot()?	Scatter point locations; Plot lines/connected curves।
353	plt.show() কী?	Matplotlib figures display করে।
354	assert কী?	Condition false হলে AssertionError ওঠায়।
355	make_pipeline() কেন?	Preprocessing ও model training একসঙ্গে রেখে leakage কমাতে।

APPENDIX B | Search Algorithms & Formula Revision

বিভিন্ন Set-এর Search সমস্যা ও Mathematical Calculation একই সূত্রে পুনরায় রিভিশন করতে পারবে।

Search Algorithm Comparison

ALGORITHM	DATA STRUCTURE / SCORE	WHEN IT HELPS	CAUTION
BFS	FIFO Queue; level-order	Unit-cost graph-এর shortest-edge path	Large frontier memory
DFS	Stack / recursion; deep-first	Backtracking ও exploration	Not necessarily shortest
DLS	Depth-first + fixed limit	Bounded-depth problems	Cutoff may miss deeper goal
IDDFS	DLS at limit 0,1,2,...	Unknown goal depth	Repeated upper-level visits
UCS	Priority Queue, min g(n)	Nonnegative-cost least-cost routes	No heuristic guidance
Greedy	Priority Queue, min h(n)	Fast heuristic goal-directed search	Not optimal generally
A*	Priority Queue, min g+h	Optimal routes with sound heuristic	Memory and heuristic quality
Bidirectional	Two BFS frontiers	Known goal, reversible path search	Reverse graph/frontier join

Search Algorithm — Viva-Friendly Steps

BFS Start Queue-তে; front pop → goal check → unvisited neighbors enqueue → repeat।

DFS Start Stack-এ; top pop → goal check → neighbors push → dead-end backtrack।

DLS DFS কিন্তু depth==limit হলে deeper child expand নয়; cutoff/failure/success distinguish।

IDDFS For limit=0,1,2,...: DLS run; success হলে stop।

UCS Min cumulative g cost-এর path pop; neighbor cost relax; goal best-cost pop হলে return।

Greedy Min heuristic h node pop; neighbor add; visited handle; goal reached হলে return।

A* Min f=g+h pop; new_g calculate; better path হলে best_g/heap update; goal pop হলে return।

Bidirectional Start ও Goal থেকে frontier expand; common node-এ meeting; half-path join।

Essential Math Formulas

TOPIC	FORMULA / INTERPRETATION
A*	g(n) = actual cost from start; h(n) = estimated remaining cost; f(n)=g(n)+h(n)।

TOPIC	FORMULA / INTERPRETATION
Euclidean Distance	$d(x,y) = \text{sqrt}(\Sigma_i (x_i - y_i)^2)$ ।
Manhattan Distance	$d = \lvert x_1 - x_2 \rvert + \lvert y_1 - y_2 \rvert$ (2D) ।
Standardization	$z = (x - \mu)/\sigma$ ।
Linear Regression	$\hat{y} = m\,x + c$; $m = \Sigma(x-\bar{x})(y-\bar{y})/\Sigma(x-\bar{x})^2$; $c = \bar{y} - m\,\bar{x}$ ।
Coefficient of Determination	$R^2 = 1 - SSE/SST$; $SSE = \Sigma(y-\hat{y})^2$; $SST = \Sigma(y-\bar{y})^2$ ।
Accuracy	$(TP+TN)/(TP+TN+FP+FN)$ ।
Precision	$TP/(TP+FP)$ ।
Recall	$TP/(TP+FN)$ ।
F1	$2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$ ।
Decision Tree Gini	$\text{Gini} = 1 - \Sigma_i\, p_i^2$ ।
Decision Tree Entropy	$H = -\Sigma_i\, p_i \log_2(p_i)$ ।
K-Means Centroid	$\mu = (1/m) \times \Sigma\, x_i$ (cluster members) ।
K-Means Inertia	$\Sigma_i \lvert\lvert x_i - \mu_{\text{assigned}(i)} \rvert\rvert^2$ ।
Silhouette	$s(i) = [b(i) - a(i)] / \max(a(i), b(i))$ ।

ছয়টি Worked Calculation — স্যার যেভাবে জিজ্ঞেস করতে পারেন

1. A* g, h, f S→B cost 4, B→D cost 1; তাই $g(D)=5$। যদি $h(D)=2$, তাহলে $f(D)=5+2=7$।

2. Euclidean vs Manhattan (2,3) থেকে (5,7): Euclidean $\text{sqrt}(3^2+4^2)=5$; Manhattan $\lvert 3\rvert+\lvert 4\rvert=7$।

3. Centroid Points (2,4),(4,6),(6,8) → centroid $((2+4+6)/3,(4+6+8)/3)=(4,6)$ ।

4. Inertia Points 2,4,6; centroid 4; inertia $=(2-4)^2+(4-4)^2+(6-4)^2=8$।

5. Silhouette a=2, b=6 → $(6-2)/6 = 0.667$ (approximately) ।

6. Confusion Matrix Accuracy Correct diagonal 15+15+14=44, total 45 → accuracy=44/45×100=97.78%。

APPENDIX C | Set-Wise Output and Tricky Comparison

এখানে যে numbers-গুলো প্রায়ই viva-তে আসে, সেগুলো শেষ মুহূর্তে রিভিশন করার জন্য সংকলিত।

SET	OUTPUT / MESSAGE TO REMEMBER
01	Vacuum all clean → NoOp। BFS path A-B-D-G, DFS same; k-NN best k=5: 44/45 correct=97.78%।
02	Cold ছাড়া WearJacket নয়। DLS limit 2 cutoff, 3 success। Regression pred(7)=15.4 original।
03	FOL parent chain → grandparent। A* cost 8; h=0→UCS। K-Means selected k=2 by silhouette।
04	Bidirectional P-Q-S-V। WEKA J48/IBk GUI task। Regression original y=2x+1, pred(15)=31।
05	Three-room all clean → NoOp। Greedy cost 9 vs A* 8। Best tree depth=3 at 97.78% test।
06	PaidFee প্রয়োজন eligibility-তে। BFS/DFS/IDDFS path S-A-C-G। k-NN & tree both 97.78% (different errors)।
07	Self-sibling false। Greedy heuristic modified expansion 4→5। K-Means scaled vs unscaled inertia directly comparable নয়।
08	DLS limit 2 cutoff, 3 success। WEKA preprocess + IBk/J48। Regression pred(18) extrapolation।
09	Adjacency order changes DFS route। Bad h(A)=100: A* cost 7→8। Silhouette best k=2।
10	TempHigh+Rain→FanOn। BFS/Greedy/A* costs 17/11/5। Decision Tree 97.78% vs k-NN 95.56%।

Tricky Cross-Topic Viva

প্রশ্ন: FOL-এর কাজ কি Decision Tree দিয়ে করা যাবে?

উত্তর: কিছু simple fixed decision যাবে; general relation inference/forward chaining Tree-এর equivalent নয়।

প্রশ্ন: h(n) কে calculate করে?

উত্তর: Problem-specific heuristic designer/algorithm। Lab-এর h dictionary অনেক ক্ষেত্রে আগে দেওয়া থাকে; distance ব্যবহার করেও estimate করা যায়।

প্রশ্ন: BFS vs DFS: কোনটা better?

উত্তর: Same-cost edges-এ shortest path guarantee চাইলে BFS। DFS কম expanded node পেতে পারে, কিন্তু shortest guarantee নেই।

প্রশ্ন: K-Means-এ K কীভাবে নির্বাচন?

উত্তর: Elbow trend, highest feasible silhouette, domain context, stability।

প্রশ্ন: k-NN vs K-Means-এর k একই?

উত্তর: না; neighbors বনাম clusters।

প্রশ্ন: Scaling সবসময় good?

উত্তর: না; distance-based method-এ প্রভাব বড়, কিন্তু quality কখনো কমে।

প্রশ্ন: Accuracy একই হলেও model আলাদা কেন?

উত্তর: Errors কোথায় হচ্ছে, precision/recall ও inductive assumptions ভিন্ন।

প্রশ্ন: A* কি always optimal?

উত্তর: না; graph setting, nonnegative costs ও heuristic properties প্রয়োজন।

উৎস ও পুনরায় যাচাই

মূল experiment mapping এবং code reference: ICT-4202-AI-ML-Laboratory GitHub repository — https://github.com/SajjadHossainSoykot/ICT-4202-AI-ML-Laboratory

এই handbook পূর্ববর্তী আলোচনার Set 01–10 notes এবং 355 core viva Q&A পুনর্গঠন করে প্রস্তুত। এটি official question paper বা official marks scheme-এর বিকল্প নয়।

Final tip: প্রতিটি program-এর জন্য Objective → Algorithm → Output কীভাবে এলো → Comparison → Advantage/Limitations → Real-world Use—এই ৬টি বিষয় বলতে পারলে viva-তে আত্মবিশ্বাস বাড়বে।